

厚德 求真 砺学 笃行



西安电子科技大学
XIDIAN UNIVERSITY

图像理解与计算机视觉

世界模型介绍

人工智能学院

01

研究背景

03

主要技术

05

最新研究进展

07

遥感中的
世界模型

02

世界模型是什么

04

技术路线详解

06

实际应用

08

未解决的问题
与未来方向

研究背景

PART ONE




西安电子科技大学
XIDIAN UNIVERSITY



Transformer与基础模型的演进

- **Transformer**用自注意力替代了传统循环结构，使模型可以并行处理长序列，并且更容易在大数据和大算力条件下扩展。
- 沿着这一路线，基础模型已经从稠密网络发展到**MoE**、长上下文和检索增强架构，因此既能保持通用能力，也能降低部分场景下的推理成本。
- 这类模型现在能支撑文档分析、代码生成、跨模态问答和科研知识整理等任务，是许多智能体系统的底层能力来源。
- 它的挑战在于注意力计算仍然昂贵、上下文越长越难稳定利用，而且模型往往会记住形式而不是因果结构。

Scaled Dot-Product Attention




Multi-Head Attention



大语言模型的发展脉络

- 大语言模型的核心变化，是把语言建模从“预测下一个词”扩展成“学习世界知识、任务接口与交互习惯”的通用表示学习问题。
- 在指令微调、偏好对齐和工具使用加入之后，模型不仅能写作和摘要，还能调用搜索、代码执行和数据库接口完成复合任务。
- 这让非AI专业的科研人员可以把模型当作“语言外壳下的统一软件接口”，从而更快地组织实验流程与资料分析。
- 但大语言模型仍容易出现事实幻觉、步骤跳跃和不可解释的偏差，所以专业结论必须经过外部证据、规则系统或人工复核。

大语言模型演进



(1) Hotspot QA

Question: Aside from the Apple Remote, what other device can control the program Apple Remote was originally designed to interact with?

(1d) ReAct (Reason + Act)

Thought 1: I need to search Apple Remote and find the program it was originally designed to interact with.

Act 1: Search[Apple Remote]

Obs 1: The Apple Remote is a remote control introduced in October 2005 by Apple ... originally designed to control the Front Row media center program ...

Thought 2: Apple Remote was originally designed to control the Front Row media center program. I need to search Front Row next and find what other device can control it.

Act 2: Search[Front Row]

Obs 2: Could not find [Front Row]. Similar: ['Front Row Seat to Earth', 'Front Row Motorsports', 'Front Row (software)', ...]

Thought 3: Front Row is not found. I need to search Front Row (software) .

Act 3: Search[Front Row (software)]

Obs 3: Front Row is a discontinued media center software ...

Thought 4: Front Row (software) is controlled by an Apple Remote or the keyboard function keys. So the answer is keyboard function keys.

Act 4: Finish[keyboard function keys]






- 最近一轮多模态研究的明显变化，是把图像、语音、视频与文本映射到更统一的表示空间，因此一个模型可以同时“看懂、听懂、说出并解释”复杂场景。
- 这种能力能直接支持实验记录理解、设备巡检图像分析、语音问答助手和多源数据联合报告生成。
- 以 Microsoft Research 公布的 Phi-4 Reasoning-Vision 一类工作为代表，新一代系统更强调跨模态推理链和共享记忆，所以在复杂场景中的交互更自然。
- 不过，多模态一致性仍然是难点，特别是在视频时序、细粒度空间定位和低质量工业图像上，模型仍会出现漏检、误解和时间顺序错误。



为什么这一轮人工智能影响更广？

- 它不再只服务于特定实验室和特定任务
- 开始面向知识工作、科研工作和复杂业务流程
- AI 使用率显著提升：2024 年有 78% 的组织报告在使用 AI，而 2023 年是 55%。
- 这意味着人工智能正在从“技术热点”转变为“通用能力基础设施”





智能体系统正在形成

- Agent系统把模型从“回答问题”推进到“完成任务”，其关键不是单次生成更长文本，而是学会规划、调用工具、执行步骤并根据结果回退。
- 这类系统现在已经能处理网页操作、代码调试、文献检索、报告撰写和多软件协同等流程型工作。
- 对科研场景而言，智能体最值得关注的是它能把人从重复性的软件操作里解放出来，让研究者更多关注假设、设计和判断。
- 当前瓶颈是任务边界不清时容易失控，外部环境稍有变化就可能计划失效，而且权限管理、操作审计和失败恢复都还不成熟。



智能体闭环





具身智能与VLA模型

- 具身智能把感知、语言和动作统一到同一个控制闭环中，**VLA**模型就是用视觉与语言条件直接生成机器人动作的一类代表方法。
- 这类系统能做的事情包括示教学习、抓取与搬运、巡检辅助和在半结构化环境中完成多步骤操作，因此比传统机械臂脚本更灵活。
- 最近以 Gemini Robotics 为代表的工作，说明模型正在从“会描述世界”进一步走向“能在世界中行动”，这也是基础模型向物理空间延伸的关键一步。
- 但现实环境中的摩擦、遮挡、光照变化和安全约束远比仿真复杂，所以数据采集成本高、泛化能力不足仍然是主要挑战。




Gemini Robotics
brings AI into the
physical world




AI for Science正在加速突破

- AI for Science的核心不是替代科学规律，而是把表征学习、生成建模和高效搜索用于分子结构、材料设计、天气预测和实验流程优化。
- 以 AlphaFold、GraphCast 一类成果为代表，这一方向已经能帮助研究人员更快筛选候选结构、预测部分物理量并缩短从假设到实验验证的迭代周期。
- 这一方向最重要的意义，在于把“海量候选中找少量可行解”的问题转化为模型辅助搜索问题，因此特别适合高成本实验领域。
- 不过，科学问题往往受守恒律、边界条件和测量噪声约束，单纯追求预测精度并不足够，模型必须与机理知识和实验闭环结合。



AlphaFold 2 Architecture




生成式 AI 发展迅速

如今的AI看起来似乎“无所不能”：能写深奥的论文、复杂的代码，做出顶级的画面和视频。


文稿生成

- 摘要、润色、检索增强写作



代码生成

- 补全、调试、测试、脚手架生成



图像 / 视频

- 文生图、文生视频、多模态编辑



今天的 AI 已经很擅长生成像样的内容，但还不等于真正掌握了世界如何运转。

为什么这还不够？

“大模型会说” 不等于 “系统真正理解并预测现实世界”

会回答当前问题

不等于

理解世界中的对象、关系与因果

会识别眼前状态

不等于

预测下一步会发生什么

会生成看似合理的内容

不等于

在真实环境中稳定规划并行动



不符合现实场景




狼崽凭空分裂出现，又合并消失

对世界状态、变化规律、行动后果的统一建模仍然不足。

世界模型成为新焦点

为了解决这个问题，OpenAI、谷歌、微软等大公司，Yann LeCun、李飞飞等顶尖学者都开始研究同一件事，那就是——世界模型。



Google DeepMind Genie

- 从视频中学习可交互环境
- 把“看视频”推进到“可操作世界”



OpenAI Sora

- 强调长时序、时空一致性
- 让视频生成更接近动态世界模拟



李飞飞

- 认为智能不能只停留在语言层
- 还要走向空间、感知与行动



Yann LeCun

- 多次强调世界模型的重要性
- 把它视作高级智能的关键部件

如果这条路线成功，会改变什么？

大家普遍期待：多模态与世界模型一旦结合成熟，人工智能将完成从“仅能感知”到“具备认知与推理”的跨越，这将深刻地重塑科技、生产力以及人机关系。

迈入具身智能时代

- 机器人具备物理常识，理解重力、碰撞等物理规律
- 自动化自主操作，在复杂、未知环境中自主决策工作

各行业研发规划范式变革

- 自动驾驶的跃升，模拟成千上万种危险场景
- 科研与设计效率突破，材料、生物学等领域实现突破


生成模型走向模拟

- 高仿真环境预测，生成连续、符合逻辑的“未来视频”
- 反事实推理，AI具备假设性思维能力，规划问题。

世界模型是通用人工智能的重要拼图，如果世界模型路线成立，AI的核心范式不再仅是处理文本或图像的工具，而是能够学习并理解其运作所在的真实世界。

他们都可以被称为世界模型吗？

当视频生成、机器人、自动驾驶等领域都开始使用这个词，世界模型又该怎么定义



世界模型？

1

只会生成画面

更像高质量内容生成

2

能预测状态演化

开始触及世界模型的核心能力

3

能基于预测规划行动

才更接近完整的世界模型

真正的关键不在于是否生成了**世界的样子**，
而在于是否学会了**世界的结构、变化和行动后果**。

世界模型是什么

PART TWO



西安电子科技大学
XIDIAN UNIVERSITY

世界模型是什么

所以世界模型到底是什么？会是人类通往AGI的必经之路吗

我们每天的判断，本质上都在使用一个脑中的“小世界”。


- 太阳东升西落：形成稳定规律
- 松开水杯会掉落：理解物理因果
- 乌云密布可能下雨：进行经验预测
- 看见球滚向桌边：会预判它可能掉下去



想象

预演

世界如何运作




在我们小时候就在大脑中构建了一个小世界，并对其进行想象、预演，在认知科学中这被称为心智模型（mental model）

1943年

从心智模型开始： Craik 的早期洞见

世界模型的思想源头之一，来自认知科学中的“心智模型”。



kenneth craik

在上个世纪，人们就已经开始研究心智模型

1943年，kenneth craik在其著作《解释的本质》中就提到：
人在对现实做出反应之前，会先在大脑中构建一个“小规模的世界模型”，用它来模拟可能发生的过程，在根据此选择行动。

心智模型
Metal model



模拟过程



选择行动

1991年


Dyna: 把世界模型写进智能体架构

智能体不只学策略，也要学环境模型，并在内部做“想象中的训练”。

- 1991 年，Sutton 提出《Dyna, an Integrated Architecture for Learning, Planning, and Reacting》
- 世界模型在这里第一次被明确纳入智能体的基础能力框架
- 也就是说：学会行动策略的同时，也要学会“世界是如何响应我的动作的”



强化学习之父
Richard Sutton



真实交互



学习环境模型



内部想象推演



更新策略/价值

2018年

机器要想具备真正的智能知否也需要构建一个属于自己的世界？


这篇工作把世界模型拆解为一个很清晰的“看见 - 记住 - 行动”闭环。



Google brain
David Ha



LSTM之父
Juergen
Schmidhuber



World models

V**Vision**

把观察压缩为潜在状态

M**Memory**

预测潜在状态如何演化

C**Controller**

根据内部预测做出动作

2018年世界模型 worldmodels 正式被提出。

世界模型不只是记住画面，而是要把感知、时间和行动组织成一个闭环系统。

所以，世界模型至少应包含三件事

从定义上看，世界模型不是单一模块，而是一组连续能力。

世界模型应该包含三部分内容：

表示世界

对象、关系、状态、约束

未来预测

状态如何随时间与动作变化

规划行动

在内部模拟后选择更优动作

只有同时具备“表示、预测、规划”三部分，世界模型才真正从概念走向应用。



主要技术

PART Three



西安电子科技大学
XIDIAN UNIVERSITY


世界模型：三条技术路线的汇合
从强化学习到生成模型的统一演化

强化学习

- 决策与规划
- 环境动态建模

表征学习

- 抽象表示
- 语义理解




生成模型

- 未来观测生成
- 时空建模

世界模型并非单一路径的产物，而是三种核心能力的融合：行动，理解与生成。

世界模型概念确定：V-M-C模块框架



模块化设计：将感知、记忆与决策解耦。


- 1. 感知(感知压缩)
 - ◆ 将高维图像映射到低维潜在空间
 - ◆ 提取关键视觉信息，降低建模复杂度
- 2. 记忆（动态建模）
 - ◆ 使用RNN构建时间依赖性
 - ◆ 预测未来状态，捕捉环境动态
- 3. 控制器（决策模块）
 - ◆ 基于状态进行决策，输出动作
 - ◆ 输出动作，与环境进行闭环

优点：结构清晰，可解释性强
局限：模块割裂，难以端到端优化

从建模世界到在世界里训练-强化学习路线


Dreamer：在潜在世界中学习

基线：真实世界训练



范式转变

Dreamer：潜在虚拟世界训练



核心突破


- 不依赖真实环境交互
- 在潜在世界中进行策略优化

核心机制

- latent dynamics (RSSM)
- imagination rollout
- 减少真实环境试错成本

从预测像素到预测理解-表征学习路线

JEPA: 预测表示，而非像素



世界模型看见未来-视频生成路线

目标从“下一帧”扩展到更长跨度的一致未来



Dreamer: 仅潜在空间

- 仅潜在空间
- 无视觉想象
- (不可观测)

JEPA: 仅表征学习

- 仅表征学习
- 无生成能力
- (不可观测)

无可视化, 适配任务广

视频生成 (Sora)

- 生成器、视频、图像...
- 可视化、可控制

交互世界模型 (Genie, GAIA)

- 可交互、可操控
- 可视化、可控制

范式转变



预测
潜在空间预测



表征
表征学习




生成
可视化生成

世界模型，本质在预测什么

VMC


模块化世界模型



潜状态

Dreamer


强化学习



潜空间规划

JEPA

表征预测




表征预测

Video

生成未来

Agent

走向交互



3D生成 (可交互)



技术路线详解


PART FOUR



西安电子科技大学
XIDIAN UNIVERSITY

世界模型的本质转变

世界模型的本质，是从'理解世界'走向'构造世界'



表示方式的变化:

Modules → End-to-End Systems

早期的显式模块拆分 (VMC) 演进为统一的 latent / transformer 世界模型。

结论：世界建模开始“内化”为一个整体系统

建模对象的变化: Pixels → Representations

从低效且不稳定的像素预测，演进为稳定且可泛化的表征预测。

结论：世界不再是图像，而是结构

目标函数的变化:

Prediction → Generation + Interaction

从被动的预测，演进为主动的生成与闭环交互。

结论：世界模型不再是预测器，而是世界模拟器


表征预测：在潜在语义空间中理解未来

表征预测的目标：不直接生成像素，而是在潜在语义空间中预测未来状态

信息压缩 → 预测未来表示

输入

编码器



解码器

未来表示

方法本质

- 将高维输入编码为紧凑 embedding
- 在 latent space 中进行未来预测
- 学习未来“语义表示”而非像素

与世界模型的关系

- 世界模型：显式建模环境动力学，我知道世界如何变化
- 表征预测：隐式建模未来表征，我预测未来的表示长什么样

代表方法：MAE / VideoMAE

随机遮蔽输入的部分区域，训练模型预测被遮蔽部分的表征。迫使模型学习全局语义而非局部纹理。


方法类别：表征预测的三大范式

Predictive Latent Modeling



代表方法：JEPA / I-JEPA
在潜在空间中直接预测未来表征，无需生成像素。核心思想：好的表征应能预测未来，而非重建过去。

Contrastive Representation Learning



代表方法：CPC / SimCLR
通过对比正负样本对来学习紧凑表征。拉近语义相似样本，推远语义不同样本，形成结构化潜空间。

Masked Prediction




生成未来


通过条件生成的方式，直接生成未来的观测序列（视频/世界演化）

面向的问题

1. 复杂世界动力学难以建模



2. 长期预测误差累积




3. 像素级 rollout 不稳定




Text / Prompt
(输入)




Tokenization /
Conditioning
(条件化)




Diffusion /
Autoregressive Model
(核心模型)



Video
Decoder
(视频解码)



Video
(生成视频)




生成模型通过学习数据分布 $P(\text{video}|\text{context})$ ，以采样方式生成未来世界

核心方法分类

1. Diffusion Video Models (Sora / Video Diffusion)
2. Autoregressive Video Models (VideoGPT)
3. Latent Diffusion Models

交互式世界模型：三大技术路线

路线 1：动作-视频



- 输入：(s, a) -> 输出：视频
- 方法：扩散，变换器
- 能力：可控生成

以动作为条件的视频 (主线🔥)

$(s_t, a_t) \rightarrow s_{t+1}$ (pixel/video)
扩散 / 视频变换器 + 动作标记
视觉可控交互 (game / robotics)

- 👉 本质：可控生成
- 👉 视频模型 + 动作 = 交互式世界

路线 2：潜空间 + 强化学习



- 输入：(z, a) -> 输出：潜空间
- 方法：世界模型 + 强化学习策略
- 能力：规划

潜空间世界 + 策略 (Dreamer系)

潜空间 $z_t \rightarrow z_{t+1}$
世界模型 + 强化学习策略
规划 / 想象

- 👉 本质：内部交互
- 👉 交互发生在潜空间中

路线 3：模拟



- 输入：(状态, a) -> 输出：环境
- 方法：神经网络引擎，模拟器
- 能力：可执行世界

模拟优先 (Genie / 可执行世界🔥🔥)

世界 = 环境
agent 可直接操作
长期一致 + 实时反馈


- 👉 本质：世界执行
- 👉 不是生成帧，而是生成世界

三条路线本质区别： Route 1：生成世界（可视化） Route 2：想象世界（规划） Route 3：运行世界（执行）

从交互到可执行世界

世界模型能力的纵向进化

✦ 每一层的“能力跃迁”



世界模型的演化本质：从 '预测未来' → '响应动作' → '承载交互'
终极形态：World Model = Interactive Environment



最新研究进展

PART FIVE



西安电子科技大学
XIDIAN UNIVERSITY

R2-Dreamer: World Models without Decoders

问题

- 像素重建 = 错误目标
学习背景纹理 $\neq$ 学习决策所需表征
- 解码器 = 计算瓶颈
大量算力浪费于图像重建，而非策略优化

实验结果

速度提升

 $1.59\times$

相比 DreamerV3 训练更快

SOTA

性能对齐

匹配 DreamerV3 & TD-MPC2

传统 Dreamer

图像 $\rightarrow$ 编码器 $\rightarrow$ 潜变量
 $\rightarrow$ 解码器 $\rightarrow$ 重构图像

R2-Dreamer

图像 $\rightarrow$ 编码器 $\rightarrow$ 潜状态 $\rightarrow$ 线性投影器

R2-Dreamer 核心

无解码器、无数据增强、
Barlow Twins 去冗余

观测嵌入对齐

观测嵌入 $\leftarrow$ 线性投影器，潜
状态对齐

冗余去除

通过 L_BT (Barlow Twins) 去除
冗余

World Models 不需要重建世界——只需要理解它

冗余减少目标：
交叉相关矩阵趋近单位矩阵 学习非冗余、
信息丰富的表征，聚焦任务相关特征而非视觉细节。

方法	解码器	数据增强	速度	小目标
DreamerV3	有	无	慢	差
R2-Dreamer	无	无	快	强

优点


无重建 $\rightarrow$ 聚焦任务相关信号

在 DMC-Subtle 小目标任务上显著提升

局限性

- 无视觉想象能力（无解码器）
- 长时序任务表现较弱
- 对 batch size / 特征维度敏感

JEPA 的稳定性与物理建模突破



LeWorldModel (LeWM)

arXiv 2026, Yann LeCun 团队

Core Breakthroughs:

- 从"复杂技巧" → 端到端稳定训练
- Loss 从 6+ → 仅 2 项
- 下一帧特征预测
- Gaussian Regularizer

Results:

- 超参数: 6 → 1
- 单卡 GPU 数小时训练
- Planning 速度: 提升 48×

端到端稳定

极简训练

高效规划

从'脆弱表征学习' → '稳定可用的世界模型'

V-JEPA 2 (Video JEPA)

Meta AI, 2025-2026

Core Breakthroughs:

- 大规模自监督视频预训练
- 时空掩码预测 (Spatio-temporal masking)

Results:


- 学到真实物理动态
- Zero-shot 机器人控制
- 可操控未见物体

ZERO-SHOT 控制

物理世界理解

具身智能

JEPA 的多模态与生成能力扩展



生成式世界建模

1 实时交互：Playable World Models

From "生成视频" → "驱动世界"

Core Breakthroughs:

- 引入 Action-Conditioned Video Prediction
- 模型从被动生成 → 主动响应用户输入
- 实现 20–60 FPS 实时世界模拟

Key Significance:

- 逐步替代传统 3D 游戏引擎
- 隐式学习物理规律（碰撞 / 遮挡 / 动力反馈）

Representative Work:

- Oasis: 纯视频学习 → 实时可玩沙盒环境
- 证明 "Next-frame Prediction = 世界建模"

2 原生多模态统一：音视频一体生成

From "视频生成" → "电影级世界合成"

Core Breakthroughs:


- Audio + Video Native Joint Modeling
- Multi-Shot Storyboarding（分镜级控制）
- 角色/物体跨镜头一致性（Coreference）

Key Significance:

- 从"片段生成"进入"叙事生成"
- 解决长视频角色崩塌问题
- 支持电影级叙事控制

Representative Work:

- Kling 3.0 → 多镜头 + 多角色一致性
- Seedance 2.0 → 音视频同步生成
- Sora 2 → 长时空一致性
- Veo 3.1 → 物理级光影与流体建模



3 架构突破：Video MoE 统治高分辨率生成

From "算力瓶颈" → "专家化时空建模"

Core Breakthroughs:

- Video Transformer → Mixture of Experts (MoE)
- 时空 Patch 专家分解建模
- 在不增加推理成本下提升容量

Key Significance:

- 支撑 720P / 4K 高质量生成
- 泛化能力显著提升
- 开源生态快速统一

Representative Work:

- Wan 2.2 / Wan 2.6 → 证明 MoE 是视频生成"可扩展路径"

4 闭环世界模型：面向机器人与自动驾驶

From "生成内容" → "生成可执行世界"

Core Breakthroughs:

- 引入 Physical Feasibility Constraint
- 视频 → 动力学轨迹映射
- 世界模型成为决策模拟器

Key Significance:

- AI生成结果可直接用于控制系统
- 构建"仿真-决策-执行"闭环
- 支撑自动驾驶极端场景训练

Representative Work:

- GVP-WM: 对扩散视频进行动态可行性校准
- DrivingGen: 合成 corner cases, 用于安全验证

预测空间：世界模型的统一视角

1. 状态空间- 蓝色

预测目标：预测潜在环境状态

核心概念：

- 显式建模环境动力学 ($s_t \rightarrow s_{t+1}$)
- 学习状态转移函数 $f(s_t, a_t) = s_{t+1}$
- 强调物理约束和因果关系

代表方法：


- PlaNet / Dreamer 系列：在潜在空间中预测状态轨迹
- RSSM (Recurrent State Space Model)：循环状态空间模型
- 应用场景：强化学习、机器人

优势：

- 状态表征紧凑，计算高效
- 易于集成控制策略
- 对长期预测有较好的稳定性

局限：

- 状态定义依赖任务，泛化性有限
- 难以处理高维观测（如视频）



2. 表征空间- 紫色

预测目标：预测结构化潜在表征

核心概念：

- 学习任务无关的通用表征
- 通过对比学习或冗余减少优化
- 强调表征的不变性和可泛化性

优势：

- 表征通用性强，跨任务迁移能力好
- 无需显式建模动力学
- 计算效率高，参数量少

代表方法：

- JEPA / I-JEPA：联合嵌入预测架构
- R2-Dreamer：通过 Barlow Twins 冗余减少
- SimCLR / MoCo：对比学习框架
- 应用场景：自监督学习、表征学习、迁移学习

局限：

- 缺乏可解释性，难以理解表征含义
- 对长期预测的约束较弱

3. 像素空间- 绿色

预测目标：预测原始感官观测（视频/图像）

核心概念：

- 直接在像素或视频帧空间进行预测
- 生成逼真的未来观测序列
- 强调视觉保真度和细节

代表方法：

- Video Diffusion Models：扩散模型生成视频
- Sora：大规模视频生成模型
- VideoGPT：自回归视频预测
- 应用场景：视频生成、内容创作、视觉规划

优势：

- 生成结果直观可视化
- 可用于视觉想象和规划
- 易于人类理解和评估

局限：

- 计算成本极高，训练困难
- 像素级预测误差易累积
- 对长期预测不稳定

4. 知识空间- 黄色

预测目标：预测符号化知识和推理结果

核心概念：

- 在语言/符号空间进行推理
- 学习因果关系和逻辑规则
- 强调高层语义和推理能力

代表方法：

- 大语言模型 (LLM)：GPT、Claude 等
- 符号推理系统：知识图谱、逻辑推理
- 多模态推理：视觉-语言模型
- 应用场景：常识推理、规划、问答系统

优势：

- 推理能力强，可处理复杂逻辑
- 知识可显式表达和验证
- 泛化能力强，零样本学习

局限：

- 难以处理连续物理过程
- 符号化表示可能丢失细节信息
- 与感官观测的对齐困难

实际应用

PART SIX



西安电子科技大学
XIDIAN UNIVERSITY


从模型能力到工业场景中的实际应用

世界模型用于理解现实世界动态，通过文本、图像、视频和运动等输入数据来生成模拟实际物理环境自定义合成数据用于训练下游任务如机器人和智能汽车。


自动驾驶



机器人



复杂动力系统



内容生成、游戏与影视制作



穿戴式设备



AI Agent



世界模型应用的四类能力

场景推演与风险预判

系统必须预判几秒后、几步后、几天后的状态变化。

减少真实试错与数据成本

把一部分训练、验证和预演前移到可控环境里完成。

可交互环境生成与仿真

仿真直接进入训练流水线和验证流水线。

复杂系统预测与决策支持

重点是更快得到更可用的预测，而不是视觉效果。

场景推演、减少试错、可交互仿真、复杂系统预测，是世界模型落地的价值

自动驾驶中的世界模型应用

不是简单识别任务，而是持续推演一个多主体动态世界

汽车不是停在一张图像前做单次判断，而是在一个**持续变化、参与者众多、后果敏感**的环境里连续行动。

真正重要的问题不是
“当前画面里有哪些车、哪些线、哪些行人”
而是：

- 前车两秒后会不会变道
- 行人会不会突然横穿
- 对向车辆是否会侵入本车道
- 当前动作在几秒后会不会带来风险

世界模型能够为自动驾驶开发的各个阶段带来显著的好处。

借助预先标记的已编码视频数据，开发者可以整理和训练自动驾驶栈，使其更准确地识别车辆、行人和物体的行为。

这些模型可以基于文本和视觉输入内容创建预测型视频仿真，并生成新的场景，例如不同的交通模式、道路状况、天气和光线，以便对驱动车辆的推理型“视觉-语言-行动”模型进行后期训练，并加快测试和验证速度。



对车企和出行平台而言，世界模型的意义在于把风险验证前移，并降低跨城市迁移成本。

自动驾驶平台案例：WAYVE

从融资、平台合作到公开试点，自动驾驶世界模型正在从技术概念走向业务接口

2024

Series C

定位为 autonomy
foundation model

2024.08

Uber 合作

能力开始接入真实出行网络

2025.06

英国 L4 trials

进入公开道路与真实运营约束

2025

Nissan 关注

OEM 开始把它视为升级路径

英国自动驾驶技术公司Wayve 是一个非常有代表性的样本。

2024 年 8 月，Wayve 与 Uber 宣布战略合作，Uber 还追加了对 Wayve 的战略投资。

2025 年 6 月，Wayve 与 Uber 进一步宣布将在英国开展 L4 自动驾驶公开道路试验。

不再只是单车 Demo，而是在向平台能力走。
世界模型开始接入车队、法规、城市复杂度与用户体验。
传统 OEM 也把它视为下一代辅助驾驶升级方向。



Wayve 代表的不是单个模型，而是一条把世界模型接进真实自动驾驶产品链路的路线。

机器人中的世界模型应用

真实世界机器人数据采集成本高昂，仅凭有限真机数据，难以覆盖各种变化

采集成本


一台设备、一个场景、一次数据采集，都要花真实成本。

试错风险

抓取失败、碰撞失稳都可能带来设备和安全问题。

环境变化

光线、摩擦、材质和摆放变化会迅速放大边界情况。



世界模型最直接的收益是更少真机试错、更快训练闭环和更低数据扩展成本。

机器人平台案例：NVIDIA Cosmos、TRI、Skild AI

平台能力、数据生成与策略训练正在形成更清晰的机器人开发链路

真实数据 / 合成数据



Cosmos / 定制 WFM



Policy / VLA 训练



部署与验证

世界模型 在机器人里的真实位置，通常处于“数据生成/增强—仿真—策略训练”这条流水线中段。

NVIDIA Cosmos

开放 physical AI 平台，提供 world foundation models、评估和后训练框架。

Physical AI

NVIDIA Cosmos

An open platform for physical AI with world foundation models (WFMs), video data processing libraries, video evaluation, and post-training frameworks.

TRI

定制 Cosmos WFMs，用于 view synthesis、teleoperation data augmentation 和 navigation world models。



Skild AI

把 Cosmos 与 Isaac Lab 结合，用合成数据扩展 locomotion 与 manipulation 训练。




复杂动力系统中的世界模型应用

核心价值集中体现为多情景推演、风险量化与决策支持


在复杂动力系统中，世界模型的应用重点并不在于视觉生成，而在于**对未来状态进行可重复推演**，并为风险评估与决策提供支撑。

天气和气候系统是典型场景：系统需要基于当前状态推演未来演化、给出多种可能情景及其概率，并支持极端事件分析。


- 更高效地产生候选预测
- 更稳定地识别极端事件与高损失风险
- 更容易嵌入运营、灾害管理、保险、能源与供应链系统



7-day forecast



5-day forecast



3-day forecast



1-day forecast

更快

更快地产生大量候选预测。

更准

更容易抓住极端天气和高损失事件。

更可决策

更容易嵌入灾害管理、保险、能源与供应链。

在复杂物理系统里，世界模型的价值更接近“可反复推演、可量化风险的动态世界”


天气预测平台案例：GenCast 与 WeatherNext / WeatherNext 2

天气预测场景中的世界模型价值集中体现为概率预测能力、平台可用性和决策支持能力

GenCast

GenCast 的关键特点是概率性集合预测。

概率性集合预测，把多种可能未来及其概率一起交给决策者。




Weather Lab：把多情景预测开放成可交互研究界面。

WeatherNext / WeatherNext 2

WeatherNext / WeatherNext 2 更强调平台可用性与服务化接口，能力已逐步进入 Google Cloud、BigQuery、Earth Engine 和天气服务相关流程。

更快、更准，并且逐步进入 Google Cloud、Earth Engine 等平台能力层。



平台价值：进入已有天气服务和研究分析 workflow。


对平台方和机构用户而言，能更快接入既有预测与决策系统，往往比单次最优分数更重要。

地理空间行业中的世界模型

该领域更常表现为多模型推理与 workflow 集成，而非统一闭环产品形态

Google 路线：Geospatial Reasoning / Earth AI

强调多个基础模型、遥感模型、地理数据源和推理代理协同回答空间问题。更像“面向地理空间的多模型世界理解 workflow”。

**Esri 路线：ArcGIS GeoAI 工作流**

把遥感 foundation models、位置嵌入和 ArcGIS 分析流程直接接入现有平台。重点不是重造 world model，而是把能力嵌进业务流程。



在地理空间行业中，世界模型相关能力更多以多模型推理与 workflow 集成的形式出现，而非统一闭环产品形态。

内容生成、游戏与影视制作中的世界模型 世界模型在“想象世界”里的爆发奇点

未来的内容创作只需要给一个世界观、一个任务、一个初始状态，模型就能自动“长出一个世界”。比如在影视行业，一个导演不需要去反复搭景、重拍、做模型，只需要定义“这是一座被雨水淹没的城市”，AI就能生成整个城市的状态变化。



实现On the fly（即时）生成的游戏。比如谷歌的Genie 3，按上下左右键，它可以On the fly（即时）生成下一秒的画面

对于内容行业，世界模型带来的不仅仅是制作效率的提升，而是一场叙事方式、创作方式、内容形式的全面重写

穿戴式设备

当前可穿戴设备，本质上还是停留在记录层面，看上去很智能，实际并不理解周围的环境。

让设备真正读懂你的3D世界，
实时推断空间结构、物体关系和潜在风险，把数字内容自然融合进现实环境。

它的预测和规划能力，会让可穿戴设备从工具变成你的“数字伙伴”。
理解你在什么环境、看什么、可能要做什么，甚至在你开口前就意识到你需要帮助。



世界模型会让可穿戴设备，从“信息终端”变成随身的“世界理解引擎”

AI Agent

Agent的一切能力，都来自与环境的交互：执行动作，接收反馈。
但真实世界太昂贵、太缓慢，也太危险，几乎不可能支撑大规模试错。

世界模型并不是让Agent立刻变得更聪明，而是第一次为Agent提供了一个可训练、可试错、接近真实的世界



世界底座是真正决定AI Agent能否走向现实世界的关键

落地形态对比

闭环系统、训练平台、预测服务与 workflow 组件构成了不同的应用交付方式

交付方式	典型方向	核心能力	工程特点
闭环系统	自动驾驶	场景推演、在线决策、真实部署验证	产品闭环清晰，法规与安全要求高
训练平台	机器人	合成数据、仿真、策略 / VLA 训练	数据与模型共同构成开发基础设施
预测服务	天气 / 复杂物理系统	多情景预测、风险量化、平台接口	结果直接服务业务系统与研究系统
workflow 组件	地理空间行业	多模型推理、GeoAI 分析、GIS 集成	更依赖现有平台与行业流程嵌入

世界模型的工程形态并不统一，其落地路径取决于行业是否存在清晰的验证链路和产品闭环

小结：实际应用中的世界模型

核心价值在于推演、验证与系统级支撑，而非单纯生成

世界模型的实际价值，取决于其是否能够进入真实业务链路并形成系统级收益。

典型价值

风险预判、数据效率、仿真能力与预测支持。

典型形态

闭环系统、训练平台、预测服务与 workflow 组件。

评价标准

可验证收益、可部署性与持续迭代能力。

不同方向的落地形态并不一致：有的进入闭环系统，有的成为训练平台核心组件，有的以预测服务或行业 workflow 形式存在。因此，评价世界模型的实际价值，应优先关注其是否能够进入真实业务链路、形成可验证收益，并支撑持续部署与迭代。



遥感中的世界模型

PART

SEVEN



西安电子科技大学
XIDIAN UNIVERSITY


遥感中的世界模型

遥感场景对世界模型提出了多尺度、多分辨率、多模态及时空一致性的复合约束
遥感把世界模型拉到更严格的条件下

多尺度

既要看局部地物，又要理解大区域地理结构


Pair 1: Multi-scale - Local vs. Global



多分辨率

同一任务会同时面对米级纹理与更粗尺度格局

Pair 2: Multi-resolution - Meter-scale Texture vs. Coarse-scale Pattern



多模态

光学、SAR、HSI、LiDAR、DEM 的成像机理并不相同

Pair 3: Multi-modal - Optical vs. SAR



时空一致性

不能只局部像真，还要在空间结构和时间演化上站得住

Pair 4: Spatiotemporal Consistency - Local Realism vs. Structural Integrity




多分辨率、多尺度、多模态异质性，是遥感世界模型的前提条件

RemoteBAGEL：空间外推路线

核心在于基于中心瓦片与方向条件学习地表结构延展规律

RemoteBAGEL 的任务定义以“中心瓦片 + 方向条件 + 目标瓦片”为基本结构。

该任务可表述为：基于已观测地表区域与方向条件，对相邻未观测区域进行空间推演；其关键差异在于模型面对的是未知空间，而不是原图中被遮挡的局部缺口。



中心瓦片
局部观测



方向条件
空间条件



目标区域
未观测空间

世界属性


道路、河流、建筑与多类地物之间存在稳定空间组合关系。
因此该方法学习的不只是纹理生成，而是地表拓扑与结构延展规律。

FusDreamer: 统一表示路线

重点在于多模态遥感观测的统一内部表示构建及其能力边界

FusDreamer 更强调多模态遥感观测的统一内部表示构建。

其核心思想是将 HSI、LiDAR、文本等异构输入组织到统一表示容器中，通过跨模态融合与知识引导形成更高层的地表语义结构。



HSI / LiDAR / Text

↓

Unified Representation

主要价值

统一表征、多模态融合、知识引导与标签效率。
更适合在标注昂贵的场景中构造统一地表表示。

主要边界

尚未形成经典动作—状态—决策闭环。
不天然提供显式长期动力学预测，也不宜直接等同于完整遥感世界模拟器。

空间推演 VS 统一表示

维度	RemoteBAGEL	FusDreamer
核心任务	方向条件的空间外推 / 未观测区域推演	多模态统一表征 / 高层知识融合
输入形式	中心瓦片 + 方向 / 动作条件	HSI + LiDAR + 文本等多模态输入
侧重点	空间推理、地理拓扑延展、场景补全	统一潜空间容器、跨模态对齐、知识引导
更接近哪类世界模型	外推 / 生成 / 空间推演	内部表示 / 多模态建模
主要局限	更偏空间生成与延展，未必天然具备长期动力学闭环	统一容器不等于真正理解，也缺少明确动力学预测、交互与决策闭环

遥感世界模型的落地约束与核心难点

产品化约束与可信性约束共同决定了该方向的落地节奏

产品化约束

- 1) 数据模态复杂：跨系统、跨格式、跨时间协同成本高。
- 2) 尺度跨度大：局部目标、区域结构与长期过程需同时成立。
- 3) 验证难度高：许多任务缺乏快速统一真值反馈。
- 4) 产品闭环弱：多嵌入 GIS、灾害与环境监测流程。

地理先验

地表对象具有明确组织规律

跨尺度关联

局部合理不等于区域合理

模态鸿沟

统一表示仍需可验证对应关系

物理约束

结果需满足地理与物理一致性

遥感世界模型的关键问题不只是能否生成，而是能否形成满足多重约束的**关键世界表征**，并支撑实际任务流程

未解决的问题与

未来方向

PART

EIGHT



西安电子科技大学
XIDIAN UNIVERSITY

1.更隐蔽的模型幻觉

世界模型的错误，可能会将因果结构建错，导致系统级问题。

语言模型幻觉

- 编造事实或引用

视频模型幻觉

- 画面局部错误或运动不连贯

世界模型幻觉

- 误判重量、碰撞后果、对象关系或人物意图

可能后果

- 机器人抓取失败或动作危险
- 自动驾驶对碰撞风险判断偏差
- 构建错误的因果关系



方向

更强物理规律约束：

- 把先验规律更深地写进模型。
- 让模型学习到真实的物理规律

2.社会推断能力不足

仅模拟物理元素不足以构建先进的世界模型，因为人类行为和社会互动在许多重要场景中也发挥着至关重要的作用

问题

- 模型更擅长预测物体，却不擅长理解人的意图、规范与互动。
- 这会影响自动驾驶让行、人机协作、服务机器人等场景。

方向

- 把角色、规范、协作、博弈等社会因素纳入世界建模。
- 让模型不仅知道物体怎么动，也知道人会怎么做。

目前对生成的人类行为真实性的评估仍然主要依赖于**主观的人类评价**，这难以扩展到大规模的世界模型。因此，开发可靠且可扩展的评估方案将是未来研究的另一个方向，有助于丰富世界模型的**社会维度**。

3. 缺乏统一评测标准

由于研究追求的目标各不相同 —— 学习内部表征与预测未来世界 —— 且采用的技术方法也多种多样（例如，LLM 智能体、视频扩散），应用领域也十分广泛（自动驾驶、机器人、社交模拟），世界模型不存在单一的标准任务或指标。

视频世界模拟

- WorldSimBench
- WorldScore
- VBench / VBench-2.0
- T2V-CompBench

物理与空间推理

- PhysBench
- UrbanVideo-Bench
- Physics-IQ / T2VPhysBench
- VideoPhy / Basic Spatial Abilities

具身决策评测

- EAI
- EWMBench
- WPE
- RoboScape

尽管取得了这些进展，但对世界模型进行基准测试仍然是一个尚未解决的挑战。未来的工作应着重构建更多样化、更贴近实际的基准，以严格检验模型的泛化能力。此外，标准化评估协议对于提高**跨环境的可比性和鲁棒性**评估至关重要。

4.利用具身智能连接模拟与现实

世界模型长期被视为具身智能的重要一步，因为它可以成为智能体学习和交互的环境。


世界模型不仅是生成内容的模型，它还可以作为 embodied agent 的训练环境，帮助智能体在交互中学习。

主要挑战

- 需要更强的多模态、多任务和 3D 能力。
- 持续缩小 sim-to-real gap。
- 需要更细粒度的感知数据支持。

未来方向

建立“世界模型 ↔ 具身智能体”
相互增强的自强化闭环



当评测、仿真、真实部署和安全边界形成闭环时，世界模型才会真正从概念走向产业能力。

5. 仿真效率

确保世界模型的高效仿真对许多应用至关重要。

问题

- 大模型常用的 transformer 自回归生成方式，天然不利于高速仿真。
- 视频生成模型目前通常仅能保持几十秒的场景稳定性，容易出现物体凭空消失或位置突变的物理不一致性问题。
- 物理世界存在蝴蝶效应，建立100%精确的物理仿真在计算上是不可行的，因此需要根据实际需求平衡仿真精度与效率。



高能耗与低推理速度

未来需要从“大而慢”的生成式世界模型，走向更轻量、更高效、可实时部署的分层推理与压缩架构



长时一致性差

让世界模型从“短时连续生成”升级为“基于记忆与状态跟踪的长期稳定建模”，从而保持场景、物体和因果关系的一致性。



混沌性难以完全模拟

从追求绝对精确仿真，转向面向任务需求的近似建模，在精度、可控性与效率之间建立动态平衡。

6.伦理和安全

世界模型越接近真实世界，伦理与安全问题就越不能被忽略。

数据隐私

- 为了构建精细的世界模型，AI系统需要海量个人数据（如高维感知的视频、运动数据）来模拟现实。
- 模型可以通过零散数据推演、重建个人的敏感信息图谱，甚至预测未来的行为。这种“预知”能力极易导致隐私的侵犯和针对性的行为操控。
- 未来需要提高数据生命周期透明度，并兼顾 GDPR 等合规要求。

安全隐患

- 世界模型可能被用于模拟危险场景，降低非法和不道德活动的规划成本，因此必须建立使用层面的安全防护。
- 缺乏伦理护栏的世界模型如果脱离控制，可能会采取无法预测或危害人类安全的操作方式来达成预定目标。

权力集中和规范

- 由于世界模型需要极高算力，开发技术可能集中于少数大机构，从而形成了基于AI决策的新的权力不平等。
- 当模型能生成一致的多模态内容时，虚假信息和 deepfake 风险会更严重。未来需要检测、watermarking 以及法律责任框架。
- 当一个能够自主决策的机器人因为其内置的世界观出现偏差而导致事故，责任在法律和伦理上极难界定。

世界模型越强，越要同步推进隐私保护、安全护栏和责任规范机制。

总结：世界模型是让 AI 真正走进世界

它回答的核心问题是：如何表示世界、预测变化，并在其中行动。

从Sora的惊艳亮相到Genie的交互式世界，从李飞飞的空间智能到NVIDIA的物理AI平台，世界模型正在从实验室走向产业，从概念验证走向大规模应用。

对于AI从业者而言，现在正是布局世界模型技术栈的最佳时机。无论是投身基础研究，还是探索行业应用，世界模型都将是未来5-10年AI发展的主旋律之一。

正如Kenneth Craik在1943年的远见：“如果有机体能在头脑中携带外部现实的‘小型模型’，它就能尝试各种选择，得出最优方案，以更全面、安全和高效的方式做出反应。”

80年后的今天，我们终于开始实现这个梦想——不是在人脑中，而是在硅基智能中。世界模型，正在重新定义AI的可能性边界。

杨立昆曾说：世界模型是AI的成人礼，它让AI从纸上谈兵走向知行合一。这场变革或许才刚刚开始，但它所指向的，是一个人类与智能机器共生共荣的全新未来。在这个未来里，AI将帮我们突破自身的局限，探索更广阔的世界而这，正是技术发展的终极意义：让人类变得更强大，让世界变得更美好。

厚德 求真 砺学 笃行

感谢大家观看

Q U E S T I O N S & A N S W E R S

西安电子科技大学