

机器学习复习

Part 1

一、理论题

1. 试述什么是机器学习。

答：让机器像人类一样，通过观察大量的数据和训练，发现事物的规律，获取某种分析问题、解决问题的能力，并用它来解决实际问题。

2. 试述监督学习的概念。其与非监督学习有何不同？

答：监督学习的数据样本既有输入特征，也有输出标签。模型学习从输入数据到输出标签的映射模式，目标是在面对新的、未标记的数据时能够做出准确的预测。分类和回归是监督学习的常见任务。

非监督学习的数据样本只有输入特征，没有输出标签。模型从未标记的数据中发现模式和结构，而不是依赖于输出标签。目标是尝试找到数据的内在结构，进行聚类、降维或密度估计等任务。

3. 描述线性回归模型的数学形式。线性回归模型是如何进行预测的？

3. $h_{\theta}(x) = \sum_{j=0}^d \theta_j x_j = \theta^T x$

调整权重 θ 使模型预测值与真实值 y 尽量接近，方法是最小化损失函数，常用均方差误差作为损失函数。

4. 定义线性回归的损失函数。为什么我们选择这种损失函数？

5. 逻辑回归通常用于分类任务。解释为什么逻辑回归能够用于分类，并描述它是如何做到的。

4. 损失函数

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x_i) - y_i)^2, \text{ 即平均平方误差}$$

原因: 找到能使预测函数值与真实值差距最小的超平面。

5. 因为其通过使用 sigmoid 函数, 来输出介于 0 和 1 之间的概率值, 以用于二分类。

$$\text{即 } h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

方法:

$$\text{① 假设 } P(y=1|x;\theta) = h_{\theta}(x)$$

$$P(y=0|x;\theta) = 1 - h_{\theta}(x)$$

$$\text{则 } P(y|x;\theta) = h_{\theta}(x)^y (1 - h_{\theta}(x))^{1-y}$$

② 假设训练样本相互独立, 则其似然函数

$$L(\theta) = \prod_{i=1}^n h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$$

$$\ln L(\theta) = \log L(\theta) = \sum_{i=1}^n y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))$$

$$\frac{\partial \ln L(\theta)}{\partial \theta_j} = (y - h_{\theta}(x)) x_j$$

③ 用梯度下降法求最大似然估计。

$$\theta_j = \theta_j + \alpha \sum_{i=1}^n (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

二、线性回归

令线性回归模型为

$$y = w^T x + b$$

1. 给定损失函数为均方误差, 推导出关于权重 w 的损失函数。
2. 使用梯度下降法, 推导出更新权重 w 和偏差 b 的公式。
3. 假设采用 ℓ_2 正则化项, 给出加入正则化后的损失函数, 并推导出权重更新公式。

二.

$$1. L(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$$

$$h_w(x_i) = w^T x_i + b_i$$

$$2. \frac{\partial L}{\partial w} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i) \cdot x_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)$$

$$w \leftarrow w - \alpha \frac{\partial L}{\partial w}$$

$$b \leftarrow b - \alpha \frac{\partial L}{\partial b} \quad \alpha \text{ 为学习率}$$

$$3. L(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2 + \lambda \sum_{i=1}^n w_i^2$$

$$\frac{\partial L}{\partial w} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i) x_i + 2\lambda \sum_{i=1}^n w_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)$$

$$w \leftarrow w - \alpha \frac{\partial L}{\partial w} \quad b \leftarrow b - \alpha \frac{\partial L}{\partial b} \quad \alpha \text{ 为学习率}$$

三、感知器

1. 描述感知器的数学模型，并给出它的激活函数。
2. 用公式描述感知器的学习规则。当一个样本被错误分类时，权重是如何更新的？

$$三. 1. y = \begin{cases} 1 & w^T x + b > 0 \\ 0 & w^T x + b \leq 0 \end{cases}$$

激活函数为阶跃函数

$$\text{sign}(w^T x + b) = \begin{cases} 1 & w^T x + b > 0 \\ 0 & w^T x + b \leq 0 \end{cases}$$

空间中

2. 首先在平面上任意取超平面，计算哪些点分类错误，针对每个错误点，对取超平面逐步修正，即用随机梯度降不断极小化目标，每次随机选取一误分点

$$w_{t+1} \leftarrow w_t + y_i x_i \quad b_{t+1} \leftarrow b_t + y_i$$

误分点 $-y_i(w^T x_i + b) > 0$

损失函数：误分样本到超平面的

函数间隔之和

$$L(w, b) = - \sum_{x_i \in M} y_i (x_i^T w + b)$$

四、逻辑回归

令逻辑回归模型为

$$h_w(x) = 1 / (1 + \exp(-w^T x))$$

1. 推导出交叉熵损失函数。
2. 使用梯度下降法，推导出更新权重 w 的公式。

3. 当引入 ℓ_1 正则化项时, 写出正则化后的损失函数。

四.

1. 似然函数 $P(y|x;w) = h_w(x)^y (1-h_w(x))^{1-y}$

$$L(w) = \prod_{i=1}^n h_w(x^{(i)})^{y^{(i)}} (1-h_w(x^{(i)}))^{1-y^{(i)}}$$

$$l(w) = \log L(w) = \sum_{i=1}^n y^{(i)} \log(h_w(x^{(i)})) + (1-y^{(i)}) \log(1-h_w(x^{(i)}))$$

若要最大化 $l(w)$, 则最小化 $J(w)$, 即交叉熵损失函数

$$J(w) = - \left[\sum_{i=1}^n y^{(i)} \log(h_w(x^{(i)})) + (1-y^{(i)}) \log(1-h_w(x^{(i)})) \right]$$

2. $\frac{\partial J}{\partial w} = \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)}) x^{(i)}$ $\rightarrow J(w) = - \left[\sum_{i=1}^n y^{(i)} \log(h_w(x^{(i)})) + (1-y^{(i)}) \log(1-h_w(x^{(i)})) \right] + \lambda \sum_{i=1}^n |\theta_i|$

$$w \leftarrow w - \alpha \frac{\partial J}{\partial w}$$

五、 计算题

已知 $w_i \in \mathbb{R}, i = 0, \dots, d, \mathbf{x} \in \mathbb{R}^d$, 求下列函数的偏导数 $\frac{\partial f}{\partial w_i}$ 或梯度 $\nabla_{\mathbf{x}} f(\mathbf{x})$ 。

1. $f(w_i) = \frac{\exp(w_i) - \exp(-w_i)}{\exp(w_i) + \exp(-w_i)}$

2. $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{x}$

3. $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x}$

五.

1. $f(w_i) = \frac{e^{w_i} - e^{-w_i}}{e^{w_i} + e^{-w_i}}$

$$\frac{\partial f}{\partial w_i} = 1 - f^2(w_i)$$

2. $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{x}$


$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{x}$$

3. $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x}$

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = A \mathbf{x} + \mathbf{b}$$

一、理论题

1. 描述反向传播算法的主要步骤。




2. 解释为什么需要反向传播算法, 并如何使用它来更新神经网络的权重和偏置?

为什么: 反向传播的目标是最小化损失函数, 即模型在训练数据上的预测误差。通过计算损失函数对网络参数的梯度, 然后利用梯度下降或其他优化算法来更新模型的权重和偏置, 以最小化模型对训练数据的误差。这个过程是迭代进行的, 通过多次使用反向传播和参数更新, 逐渐调整模型的参数, 使其能够更好地拟合训练数据。

如何: 反向传播利用链式法则来计算梯度。在一个神经网络中, 每一层都有权重和偏置, 通过链式法则可以计算损失函数对每个参数的影响, 从而逐层向后传播误差。一旦梯度计算完成, 可以使用梯度下降或其他优化算法来更新网络的权重和偏置。通常的更新规则是

$\text{new_parameter} = \text{old_parameter} - \eta \times \text{gradient}$, 其中 η 是学习率, gradient 是梯度。

3. 何为链式法则? 为何它在反向传播中是关键?



通过逐层应用链式法则，可以计算整个网络中每个参数的梯度。这些梯度用于梯度下降等优化算法，通过调整参数来最小化损失函数，以逐渐提高对输入与输出之间复杂映射的拟合能力。

4. 试分析神经网络前向传播与反向传播算法的计算复杂度，并对比反向传播算法与数值差分求网络梯度方法在计算效率上的差别。

(47) 试分析神经网络前向传播与反向传播算法的计算复杂度。
并对比反向传播算法与数值差分求网络梯度方法在计算效率上的差别。

$$FP: O((M(D+1) + K(M+1))^2)$$

$$BP: O(M(D+1) + K(M+1))$$

设网络中权值和偏置总数为 w 。

$$\left\{ \begin{array}{l} \text{反向传播 } O(w) \\ \text{数值导数 } O(w^2) \end{array} \right.$$

反向传播计算效率远高于数值差分！

5. 能否将隐藏层的激活函数用线性函数替换，为什么？

6. 使用神经网络的动机是什么？



(6) 能否将隐藏层的激活函数用线性函数替换，为什么？

NO. 线性激活函数只能表达线性运算，这样多层网络与单层网络没有区别。相当于无隐藏层。激活函数的存在是为了神经网络更好地拟合目标函数。非线性函数可增强神经网络的表达能力。

(7) 使用神经网络的动机是什么？

感知机只能解决线性问题。“异或”问题等非线性可分问题需通过神经网络解决。

7. 试手工构造一个可以求解“异或”分类问题的神经网络。




二、 计算题

考虑一个三层神经网络（一个输入层、一个隐藏层、一个输出层）：

- 输入层有 1 个神经元，隐藏层有 2 个神经元，输出层有 1 个神经元。
- 输入为 $[0.5]$ 。
- 初始化的权重和偏置为：
 - 输入层到隐藏层权重 $[0.15], [0.25]$
 - 输入层到隐藏层偏置 $0.2, 0.3$
 - 隐藏层到输出层权重 $0.4, 0.5$
 - 隐藏层到输出层偏置 0.6

使用 Sigmoid 作为激活函数。

1. 手动执行一次前向传播，计算输出。
2. 假设期望输出为 1，计算输出层的误差。
3. 使用反向传播算法，计算隐藏层到输出层的权重梯度。
4. 使用学习率为 0.1，更新隐藏层到输出层的权重。



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$1. z_1^{[1]} = 0.15 \times 0.5 + 0.2 = w_{11}^{[1]}x + b_1^{[1]} = 0.15 \times 0.5 + 0.2 = 0.275$$

$$a_1^{[1]} = \sigma(z_1^{[1]}) = 0.568$$

$$z_2^{[1]} = w_{21}^{[1]}x + b_2^{[1]} = 0.4 \times 0.5 + 0.3 = 0.425$$

$$a_2^{[1]} = \sigma(z_2^{[1]}) = 0.605$$

$$z^{[2]} = w_{12}^{[2]}a_1^{[1]} + w_{22}^{[2]}a_2^{[1]} + b^{[2]} = 1.190$$

$$\hat{y} = \sigma(z^{[2]}) = 0.767$$

$$2. e = 4 - \hat{y} = 0.233$$

$$3. \frac{\partial \hat{y}}{\partial w_{12}^{[2]}} = \frac{\partial \hat{y}}{\partial z^{[2]}} \cdot \frac{\partial z^{[2]}}{\partial w_{12}^{[2]}} = \hat{y} \cdot (1 - \hat{y}) \cdot a_1^{[1]} = 0.102$$

$$\text{同理} \frac{\partial \hat{y}}{\partial b^{[2]}} = \hat{y} \cdot (1 - \hat{y}) \cdot 1 = 0.179$$


$$4. w_{12}^{[2]} = w_{12}^{[2]} + 0.1 \times 0.102 = 0.4102 \approx 0.410$$

$$w_{22}^{[2]} = w_{22}^{[2]} + 0.1 \times 0.108 = 0.5108 \approx 0.511$$

$$b^{[2]} = b^{[2]} + 0.1 \times 0.179 = 0.6179 \approx 0.618$$

三、神经网络分析

已知某分类神经网络结构如右图所示，输入变量为 D 维，隐藏变量为 M 维，输出变量为 K 维。隐藏层与输出层的激活函数均为 $\sigma(a) = \frac{1}{1 + \exp(-a)}$ 。



1. 试说明模型参数 $w^{(1)}$ 与 $w^{(2)}$ 的维度，注意考虑两个网络层均包含偏置项；
2. 试给出该网络矢量形式的前向传递函数；
3. 试给出第一层网络参数的导数 $\frac{\partial y_k}{\partial w_{md}}$ ；

$$(1) W^{(1)}: M \times (D+1)$$

$$W^{(2)}: K \times (M+1)$$

(2) 网络向量形式的前向传递函数.

$$y_k(x, w) = \sigma \left(\sum_{j=1}^M w_{kj}^{(2)} h \left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \right) + w_{k0}^{(2)} \right)$$

$$\begin{aligned} (3) \frac{\partial y_k}{\partial w_{md}} &= \frac{\partial y_k}{\partial a_k} \frac{\partial a_k}{\partial z_j} \frac{\partial z_j}{\partial a_j} \cdot \frac{\partial a_j}{\partial w_{md}} \\ &= y_k(1-y_k) \cdot w_{kj} \cdot z_j(1-z_j) \cdot x_i \end{aligned}$$

注: sigmoid求导

$$\frac{d\sigma(x)}{dx} = \sigma(x) \cdot (1 - \sigma(x))$$

四、 翻译题: 请给出以下术语的英文翻译

1. 神经网络

2. 过拟合

3. 正则化

4. 随机梯度下降

5. 逻辑回归

6. 线性回归

7. 广义线性模型

8. 均方误差

9. 平均绝对误差

- Neural network
- Overfitting
- Regularization
- Stochastic gradient descent
- Logistic regression
- Linear regression
- Generalized linear model
- Mean squared error

- Mean absolute error

Part 3

一、数据降维与特征选择

1. 使用数据降维算法的目的是什么？

- 数据可视化
- 预测的可解释性
- 加快算法的收敛，降低计算复杂度
- 数据可能占据一个比当前维数更低的流形，减少冗余信息带来的误差
- 缓解维数灾难，防止数据样本稀疏，模型过拟合

2. 主成分分析与线性鉴别分析有什么区别？

(2) 主成分分析与线性判别分析有什么区别？

PCA

LDA

① PCA是无监督的降维方法，LDA是有监督的降维方法。

② PCA无降维维数限制，LDA降维最多降到类别数 $k-1$ 的维数

③ PCA选择样本投影具有最大方差的方向，LDA选择分类性能最好的投影方向。(类内方差小，类间方差大)

④ PCA仅可以用来降维，LDA除降维，还可以用来分类。

3. 试分别从两个不同视角给出主成分分析的目标函数及求解方法

最大方差形式

原始数据 x_n 投影 $u_1^T x_n$

单位向量 $u_1^T u_1 = 1$

均值 $\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$

降维后的数据方差最大:

$$\frac{1}{N} \sum_{n=1}^N (u_1^T x_n - u_1^T \bar{x})^2 = u_1^T S u_1 \text{ — 目标函数}$$

$$+ \text{协方差矩阵 } S = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^T$$

求解方法 — 引入拉格朗日乘数

$$L = u_1^T S u_1 + \lambda(1 - u_1^T u_1)$$

$$\frac{\partial L}{\partial u_1} \Rightarrow S u_1 = \lambda u_1 \text{ 且 } u_1^T u_1 = 1$$

$$\text{故 } u_1^T S u_1 = u_1^T \lambda u_1 = \lambda = S \text{ 的最大特征值}$$

u_1 — 最大特征值对应的特征向量

多维情况: 前 m 个最大特征值

最小有用信号形式 (最小构造误差)

设定 b 个彼此正交的基向量 $\{u_i\}$

$$x_n = \sum_{i=1}^D a_{ni} u_i$$

$$\tilde{x}_n = \sum_{i=1}^M z_{ni} u_i + \sum_{i=M+1}^D b_{ni} u_i \text{ (经过压缩后重构的样本)}$$

重构误差最小:

$$J = \frac{1}{N} \sum_{n=1}^N \|x_n - \tilde{x}_n\|^2 \text{ — 目标函数}$$

$\{a_{n1} - a_{nD}\}$ 由 $\{x_{n1} - x_{nD}\}$ 与 μ_j 做内积即得.

$$a_{nj} = x_n^T \mu_j$$

$$x_n = \sum_{i=1}^D (x_n^T \mu_i) u_i$$

$$J = \frac{1}{N} \sum_{n=1}^N \left\| \sum_{i=1}^D (x_n^T \mu_i) u_i - \sum_{i=1}^M z_{ni} u_i - \sum_{i=M+1}^D b_{ni} u_i \right\|^2$$

$$\frac{\partial J}{\partial z_{nj}} \Rightarrow z_{nj} = x_n^T \mu_j$$

$$\frac{\partial J}{\partial b_{nj}} \Rightarrow b_{nj} = \bar{x}^T \mu_j$$

$$x_n - \tilde{x}_n = \sum_{i=M+1}^D [(x_n^T - \bar{x}^T) \mu_i] u_i$$

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=M+1}^D (x_n^T \mu_i - \bar{x}^T \mu_i)^2 = \sum_{i=M+1}^D u_i^T S u_i$$

优化: 引拉格朗日乘数

$$L = \sum_{i=m+1}^D u_i^T S u_i + \sum_{i=1}^D \lambda_i (1 - u_i^T u_i)$$

$$\frac{\partial L}{\partial u_i} \Rightarrow S u_i = \lambda_i u_i$$

$$u_i^T S u_i = u_i^T \lambda_i u_i = \lambda_i$$

$$J = \sum_{i=m+1}^D \lambda_i - \lambda_i \text{ 是最大的 } D-m \text{ 个特征值}$$

5. 试给出线性鉴别分析的目标函数与优化求解方法。

给出线性判别分析的目标函数与优化求解方法。

类内离散度尽可能小，类间离散度尽可能大

n维X空间

—————> 1维Y空间

$$\text{均值 } \mu_i = \frac{1}{N_i} \sum_{x_j \in D_i} x_j$$

$$\text{均值 } \bar{\mu}_i = \frac{1}{N_i} \sum_{y_j \in D_i} y_j$$

$$\text{类内 } S_i = \sum_{x_j \in D_i} (x_j - \mu_i)(x_j - \mu_i)^T$$

$$S_w = S_1 + S_2$$

$$\text{类内 } \bar{S}_i^2 = \sum_{y_j \in D_i} (y_j - \bar{\mu}_i)^2$$

$$\bar{S}_w = \bar{S}_1^2 + \bar{S}_2^2$$

$$\text{类间 } S_b = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

$$\text{类间 } \bar{S}_b = (\bar{\mu}_1 - \bar{\mu}_2)^2$$

$$J(w) = \frac{\bar{S}_b}{\bar{S}_w} = \frac{(\bar{\mu}_1 - \bar{\mu}_2)^2}{\bar{S}_1^2 + \bar{S}_2^2}$$

$$= \frac{(w^T \mu_1 - w^T \mu_2)^2}{\sum_{x_j \in D_1} (w^T x_j - w^T \mu_1)^2 + \sum_{x_j \in D_2} (w^T x_j - w^T \mu_2)^2}$$

$$= \frac{w^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w}{w^T \left[\sum_{x_j \in D_1} (x_j - \mu_1)(x_j - \mu_1)^T \right] w + w^T \left[\sum_{x_j \in D_2} (x_j - \mu_2)(x_j - \mu_2)^T \right] w}$$

$$= \frac{w^T S_b w}{w^T S_w w}$$

$$J(w) = \frac{w^T S_b w}{w^T S_w w} \quad \text{目标函数}$$

求解方法—拉格朗日乘子法。

$$L(w, \lambda) = w^T S_b w - \lambda (w^T S_w w - c)$$

$$\frac{\partial L}{\partial w} = 2S_b w - 2\lambda S_w w = 0$$

$$S_b w^* = \lambda S_w w^*$$

$$S_w^{-1} S_b w^* = \lambda w^*$$

$$w^* = \frac{1}{\lambda} S_w^{-1} S_b w^*$$

$$= \frac{1}{\lambda} S_w^{-1} (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w^*$$

$$w^* = \frac{R}{\lambda} S_w^{-1} (\mu_1 - \mu_2)$$

标量R

6. 常用的特征选择有哪些算法，分别有什么特点？
7. 滤波式与封装式特征选择方法的原理分别是什么？
8. 什么是流形学习？解释 LLE 的原理。

常用的特征选择有哪些方法, 分别有什么特点?

常见的特征选择方法大致可分为三类: 过滤式, 包裹式 和 嵌入式

(一) 过滤式选择

先对数据集进行特征选择, 然后再训练学习器, 特征选择过程与后续学习器无关。

先用特征选择过程对初始特征进行“过滤”, 再用过滤后的特征来训练模型。

(二) 包裹式选择

直接把最终将要使用的学习器的性能作为特征子集的评价准则。
为给定学习器选择最有利于其性能, “量身定做”的特征子集。

(三) 嵌入式选择

将特征选择过程与学习器训练过程融为一体, 两者在同一个优化过程中完成,
即在学习器训练过程中自动进行了特征选择。

(6) 过滤式选择与包裹式选择的原理分别是什么?

filter 设计“相关统计量”来度量特征的重要性, 每份量分别对应于一个初始特征,
子集的重要性由子集中每个特征所对应的相关统计量分量之和来决定。
需指定一个阈值 τ , 选择比 τ 大的相关统计量分量所对应的特征即可。

Wrapper 使用随机策略进行子集搜索, 以最终分类器的误差作为特征子集评价准则。

(7) 什么是流形学习? 解释 LE 的原理。

流形学习 —— 类借鉴了拓扑流形概念的降维方法。

“流形”是在局部与欧氏空间同胚的空间, 在局部具有欧氏空间的性质, 能用欧氏距离计算。

将低维流形嵌入到高维空间中, 虽数据分布复杂, 但局部上仍有欧氏空间的性质。

可容易在局部建立降维映射关系, 再设法将局部映射关系推广到全局。

流形学习 { 等度量映射 (ISomap) —— **保持近邻样本之间的距离。**
局部线性嵌入 (LLE) —— **保持邻域内样本之间的线性关系。**

(LLE) 假定样本点的坐标能通过它的邻域样本 x_j, x_k, x_l 的坐标通过线性组合重构出来。

$$x_i = w_{ij}x_j + w_{ik}x_k + w_{il}x_l \quad \text{希望此关系在低维空间中得以保持。}$$

先为每个样本 x_i 找到其近邻下标集合 Ω_i , 然后计算出基于 Ω_i 中的样本点对 x_i

进行线性重构的系数 w_i 。LLE 在低维空间中保持 w_i 不变, 求出 x_i 对应的低维空间坐标 z_i 。

一、 复习旧知

1. 如何绘制两类分类问题的 ROC 曲线与 F_1 曲线?
2. 什么是 K 折交叉验证方法? 对于训练样本集 $\mathcal{D}$, K 的最大取值是多少?
3. 什么是留一法?
4. 推导偏差-方差分解公式。
5. 请分别针对偏差与方差的大小分布的不同情况, 分析对应机器学习模型的改进策略。

模型评价

如何绘制两类分类问题的 ROC 曲线与 F1 曲线？

① ROC 曲线以“真正例率” TPR 为纵轴，“假正例率”为横轴 FPR。

分类结果混淆矩阵。

真实情况	预测结果	
	正例	反例
正例	TP	FN
反例	FP	TN

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

给定 m 个正例和 m 个反例，根据学习器预测结果，对样例进行排序，然后把分类阈值设为最大，即把所有样例均预测为反例，此时 $TPR = FPR = 0$ 。在坐标 $(0, 0)$ 处标记一个点。然后，将分类阈值依次设为每个样例的预测值，依次将每个样例划分为正例。设前一个标记点为 (x, y) 若为 TPR，则坐标为 $(x, y + \frac{1}{m})$ ，若为 FPR，则坐标为 $(x + \frac{1}{m}, y)$ 。然后用线段连接相邻点即得。

② F1 曲线

F1 是基于查准率与查全率的调和平均来定义的

$$\text{查准率 } P = \frac{TP}{TP + FP}$$

$$\text{查全率 } R = \frac{TP}{TP + FN}$$

$$F1 = \frac{2PR}{P + R}$$

什么是 K 折交叉验证法？对于训练样本集 D ，K 的最大取值是多少？

将数据集 D 划分为 K 个大小相似的互斥子集

$$D = D_1 \cup D_2 \cup \dots \cup D_K, D_i \cap D_j = \emptyset (i \neq j)$$

每次用 $K-1$ 个子集的并集作为训练集，余下的子集作为测试集。

K 组训练/测试集， K 次训练和测试，返回 K 个结果的均值。

K 的最大值为样本个数。

(3) 什么是留一法？

留一法使用的训练集与初始数据集相比只少了一个样本。

m 个样本只有唯一的方式划分为 m 个子集，每个子集包含一个样本。

留一法的评估结果往往被认为比较准确。

(4) 推导偏差-方差分解公式。

测试样本 x 。

数据集中标记 y_D

真实标记 y 。

训练集 D 模型 f 预测输出 $f(x; D)$ 。

学习算法的期望预测 $\bar{f}(x) = E_D[f(x; D)]$

使用不同训练集产生的方差 $\text{var}(x) = E_D[(f(x; D) - \bar{f}(x))^2]$ 。

噪声 $\varepsilon^2 = E_D[(y_D - y)^2]$ 。

期望输出与真实标记的差别(偏差) $\text{bias}^2(x) = (\bar{f}(x) - y)^2$ 。

假定噪声期望为 0 $E_D[y_D - y] = 0$ 。

对算法期望泛化误差进行分解：

$$E(f; D) = E_D[(f(x; D) - y_D)^2]$$

$$= E_D[(f(x; D) - \bar{f}(x) + \bar{f}(x) - y_D)^2]$$

$$= E_D[(f(x; D) - \bar{f}(x))^2] + E_D[(\bar{f}(x) - y_D)^2] + E_D[2(f(x; D) - \bar{f}(x))(\bar{f}(x) - y_D)]$$

$$= E_D[(f(x; D) - \bar{f}(x))^2] + E_D[(\bar{f}(x) - y_D)^2]$$

$$= E_D[(f(x; D) - \bar{f}(x))^2] + E_D[(\bar{f}(x) - y + y - y_D)^2]$$

$$= E_D[(f(x; D) - \bar{f}(x))^2] + E_D[(\bar{f}(x) - y)^2] + E_D[(y - y_D)^2] + 2E_D[(\bar{f}(x) - y)(y - y_D)]$$

$$= E_D[(f(x; D) - \bar{f}(x))^2] + E_D[(\bar{f}(x) - y)^2] + E_D[(y_D - y)^2]$$

$$E(f; D) = \text{bias}^2(x) + \text{var}(x) + \varepsilon^2$$

泛化误差可分解为偏差，方差与噪声之和。


分别针对偏差与方差大小分布的不同情况,分析对应机器学习模型的改进策略。

高方差(过拟合)

采用更多的训练集

减少特征数量

增加正则化系数




高偏差(欠拟合)

增加最高次数

增加特征数量

降低正则化系数



三、概率图模型

1. 什么是概率图模型?

答: 概率图模型是一类用图来表达变量相关关系的概率模型。一般而言: 图中的一个结点表示一个或一组随机变量, 结点之间的边则表示变量间的概率相关关系, 从而形成了一张“变量关系图”。

2. 贝叶斯网络和马尔可夫随机场之间有什么区别?

• 图的方向性

– **贝叶斯网络:** 使用有向无环图表示变量之间的依赖关系。有向边表示直接的因果关系, 节点的条件概率分布表示给定其父节点的情况下该节点的分布。

– **马尔可夫随机场:** 使用无向图表示变量之间的关系。无向图中的边表示变量之间的关联性, 但不指定因果关系。

• 条件独立性

– **贝叶斯网络:** 有向边表示条件依赖关系, 因此贝叶斯网络中的条件独立性是直接由图的结构来表示的。即, 一个节点在给定其父节点的情况下与其他节点条件独立。

– **马尔可夫随机场:** 通过局部马尔可夫性, 表示在给定一组邻居节点的情况下, 节点与其他节点条件独立。无向图的边表示变量之间的关系, 但不显式指定条件独立性。

• 概率分布表示

– **贝叶斯网络:** 使用联合概率分布的乘积形式, 其中每个节点的条件概率分布乘积给定其父节点的条件概率分布。

– **马尔可夫随机场:** 使用势函数的乘积形式, 其中每个因子对应于无向图中的一个子图。全局概率分布由所有因子的乘积和规范化得到。

- 应用领域

- **贝叶斯网络**：常用于推断、诊断、因果关系建模等，特别适用于处理有向因果关系的问题。
- **马尔可夫随机场**：常用于图像分割、能量最小化、模式识别等，适用于建模全局相关性和联合分布的问题。

3. 条件独立性在概率图模型中扮演什么角色？

- 模型简化：表达和利用条件独立性关系可以帮助简化概率图模型的结构。通过使用图的拓扑结构，可以快速识别哪些变量在给定其他变量的条件下是独立的，从而减少了需要建模和存储的参数数量。
- 推断：条件独立性是概率图模型进行推断的关键。当某些变量已知或观测到时，通过利用条件独立性关系，可以更有效地计算其他未知变量的后验分布，即推断。在贝叶斯网络中，有向图的结构表示了因果关系。通过条件独立性关系，可以推断在给定某些因果关系的条件下，其他变量之间是否存在依赖关系。
- 解释模型：条件独立性关系提供了对模型的直观解释。图结构清晰地显示了变量之间的关系，使得模型的结构更容易理解和解释。
- 特征选择：在特定应用中，条件独立性关系有助于确定哪些特征对于模型的预测是重要的，从而可以进行特征选择。

4. 什么是贝叶斯网？给定贝叶斯网络结构后，如何计算其联合概率？

贝叶斯网络（Bayesian Network, BN）：

贝叶斯网络是一种概率图模型，它通过有向无环图来表示变量之间的条件依赖关系。每个节点表示一个随机变量，有向边表示条件依赖关系。节点的条件概率分布描述了给定其父节点的情况下节点的概率分布。

如何计算？

计算贝叶斯网络的联合概率分布涉及到使用链式法则以及贝叶斯规则。贝叶斯网络的联合概率分布表示为各个节点的条件概率的乘积。以下是一般步骤：

假设有一个贝叶斯网络，包含随机变量 $X_1, X_2, X_3, \dots, X_k$ ，其结构由有向无环图表示。

1. 写出联合概率的链式法则：

For a graph with K nodes, the joint distribution is given by

$$p(\mathbf{x}) = \prod_{k=1}^K p(x_k | \text{pa}_k), \quad (\text{factorization})$$

where pa_k denotes the set of parents of x_k , and $\mathbf{x} = \{x_1, \dots, x_K\}$.

2. 使用贝叶斯规则进行条件概率的替代:

$$P(X_i | X_{i-1}, \dots, X_1) = \frac{P(X_i, X_{i-1}, \dots, X_1)}{P(X_{i-1}, \dots, X_1)}$$

3. 将贝叶斯网络中的条件概率替代到链式法则中:

$$P(X_1, X_2, \dots, X_n) = P(X_1) \cdot \frac{P(X_2, X_1)}{P(X_1)} \cdot \frac{P(X_3, X_2, X_1)}{P(X_2, X_1)} \cdot \dots$$

4. 简化表达式:

通过对概率项的约简, 得到最终的联合概率表达式。

5. 考虑边缘化 (如果需要):

如果只需要计算部分变量的联合概率, 可以使用边缘化 (Marginalization) 来从完整的联合概率中去除不关心的变量。例如,

$$P(X_1, X_2) = \sum_{x_3} P(X_1, X_2, X_3)$$

5. 解释马尔可夫随机场中的“团” (簇) 概念并给出一个例子

对于图中节点的一个子集, 若其中任意两结点间都有边相连, 则该结点子集为一个团。若在一个团中加入另外任何一个结点都不再形成团, 则称该团为极大团。

clique); 换言之, 极大团就是不能被其他团所包含的团。例如, 在图 14.2 中, $\{x_1, x_2\}$, $\{x_1, x_3\}$, $\{x_2, x_4\}$, $\{x_2, x_5\}$, $\{x_2, x_6\}$, $\{x_3, x_5\}$, $\{x_5, x_6\}$ 和 $\{x_2, x_5, x_6\}$ 都是团, 并且除了 $\{x_2, x_5\}$, $\{x_2, x_6\}$ 和 $\{x_5, x_6\}$ 之外都是极大团; 但是, 因为 x_2 和 x_3 之间缺乏连接, $\{x_1, x_2, x_3\}$ 并不构成团。显然, 每个结点至少出现在一个极大团中。




图 14.2 一个简单的马尔可夫随机场

6. 马尔可夫随机场如何表示其变量的联合概率分布?

在马尔可夫随机场中, 多个变量之间的联合概率分布能基于团分解为多个因子的乘积, 每个因子仅与一个团相关. 具体来说, 对于 n 个变量 $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$, 所有团构成的集合为 $\mathcal{C}$, 与团 $Q \in \mathcal{C}$ 对应的变量集合记为 $\mathbf{x}_Q$, 则联合概率 $P(\mathbf{x})$ 定义为

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q), \quad (14.2)$$

其中 ψ_Q 为与团 Q 对应的势函数, 用于对团 Q 中的变量关系进行建模, $Z =$

$\sum_{\mathbf{x}} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q)$ 为规范化因子, 以确保 $P(\mathbf{x})$ 是被正确定义的概率. 在实际应用中, 精确计算 Z 通常很困难, 但许多任务往往并不需获得 Z 的精确值.

显然, 若变量个数较多, 则团的数目将会很多(例如, 所有相互连接的两个变量都会构成团), 这就意味着式(14.2)会有很多乘积项, 显然会给计算带来负担. 注意到若团 Q 不是极大团, 则它必被一个极大团 Q^* 所包含, 即 $\mathbf{x}_Q \subseteq \mathbf{x}_{Q^*}$; 这意味着变量 $\mathbf{x}_Q$ 之间的关系不仅体现在势函数 ψ_Q 中, 还体现在 ψ_{Q^*} 中. 于是, 联合概率 $P(\mathbf{x})$ 可基于极大团来定义. 假定所有极大团构成的集合为 $\mathcal{C}^*$, 则有

$$P(\mathbf{x}) = \frac{1}{Z^*} \prod_{Q \in \mathcal{C}^*} \psi_Q(\mathbf{x}_Q), \quad (14.3)$$

其中 $Z^* = \sum_{\mathbf{x}} \prod_{Q \in \mathcal{C}^*} \psi_Q(\mathbf{x}_Q)$ 为规范化因子. 例如图 14.2 中 $\mathbf{x} = \{x_1, x_2, \dots, x_6\}$, 联合概率分布 $P(\mathbf{x})$ 定义为

$$P(\mathbf{x}) = \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6),$$

其中, 势函数 $\psi_{256}(x_2, x_5, x_6)$ 定义在极大团 $\{x_2, x_5, x_6\}$ 上, 由于它的存在, 使我们不再需为团 $\{x_2, x_5\}$, $\{x_2, x_6\}$ 和 $\{x_5, x_6\}$ 构建势函数.

回到“条件独立性”呢? 同样借助“分离”的概

现在我们来考察马尔可夫随机场中的势函数。显然，势函数 $\psi_Q(\mathbf{x}_Q)$ 的作用是定量刻画变量集 $\mathbf{x}_Q$ 中变量之间的相关关系，它应该是非负函数，且在所偏好的变量取值上有较大函数值。例如，假定图 14.4 中的变量均为二值变量，若势函数为

$$\psi_{AC}(x_A, x_C) = \begin{cases} 1.5, & \text{if } x_A = x_C; \\ 0.1, & \text{otherwise,} \end{cases}$$

$$\psi_{BC}(x_B, x_C) = \begin{cases} 0.2, & \text{if } x_B = x_C; \\ 1.3, & \text{otherwise,} \end{cases}$$

则说明该模型偏好变量 x_A 与 x_C 拥有相同的取值， x_B 与 x_C 拥有不同的取值；换言之，在该模型中 x_A 与 x_C 正相关， x_B 与 x_C 负相关。结合式(14.2)易知，令 x_A 与 x_C 相同且 x_B 与 x_C 不同的变量值指派将取得较高的联合概率。

为了满足非负性，指数函数常被用于定义势函数，即

$$\psi_Q(\mathbf{x}_Q) = e^{-H_Q(\mathbf{x}_Q)}. \quad (14.8)$$

$H_Q(\mathbf{x}_Q)$ 是一个定义在变量 $\mathbf{x}_Q$ 上的实值函数，常见形式为

$$H_Q(\mathbf{x}_Q) = \sum_{u,v \in Q, u \neq v} \alpha_{uv} x_u x_v + \sum_{v \in Q} \beta_v x_v, \quad (14.9)$$

其中 α_{uv} 和 β_v 是参数。上式中的第二项仅考虑单结点，第一项则考虑每一对结点的关系。

7. 试给出图 1 中两个概率图模型的联合概率分布。使用 $x_A, \dots, x_E$ 表示图 1(b) 中的随机变量。

$$\begin{aligned} 7. a. P(X) &= P(x_1)P(x_2)P(x_3)P(x_4|x_1, x_2, x_3)P(x_5|x_1, x_3)P(x_6|x_4)P(x_7|x_4, x_5) \\ b. P(X) &= \frac{1}{Z} \psi_{BC}(x_B, x_C) \psi_{ABED}(x_A, x_B, x_E, x_D) \\ Z &= \sum_X \prod_{Q \in \mathcal{C}} \psi_Q(x_Q) \end{aligned}$$