

机器学习（双语）

全文核心知识思维导图

第一部分 入门基础：搭建认知框架

一、核心概念辨析

1. 机器学习

定义：让机器像人类一样，通过观察大量的数据和训练，发现事物的规律，获取某种分析问题、解决问题的能力，并用它来解决实际问题。

2. 监督学习与非监督学习的区别

对比维度	监督学习	非监督学习
数据特征	数据样本既有输入特征，也有输出标签	数据样本只有输入特征，没有输出标签
学习目标	学习从输入数据到输出标签的映射模式，对新的未标记数据准确预测	从未标记数据中发现模式和结构，挖掘数据内在规律
常见任务	分类、回归	聚类、降维、密度估计

二、核心术语中英对照

- 神经网络 - Neural Network
- 过拟合 - Overfitting
- 正则化 - Regularization
- 随机梯度下降 - Stochastic Gradient Descent
- 逻辑回归 - Logistic Regression
- 线性回归 - Linear Regression

- 7. 广义线性模型 - Generalized Linear Model
- 8. 均方误差 - Mean Squared Error
- 9. 平均绝对误差 - Mean Absolute Error

三、数学基础铺垫

1. 核心运算

- 向量/矩阵运算：掌握 $w^T x$ （向量内积）、 $x^T A x$ （二次型）等基础运算，为后续模型推导奠定基础。
- 偏导数与梯度：理解单变量偏导数 $\frac{\partial f}{\partial w_i}$ 和多变量梯度 $\nabla_x f(x)$ 的定义，是参数更新的核心数学工具。

2. 常用函数

- Sigmoid 函数： $\sigma(a) = \frac{1}{1+\exp(-a)}$ ，输出范围在(0,1)之间，常用于分类模型的概率输出。
- 均方误差 (MSE)： $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ ，衡量预测值与真实值的偏差程度。

第二部分 核心基础模型：线性模型家族

一、线性回归

1. 模型数学形式

线性回归模型用于预测连续型输出，其数学形式为：

$$y = w^T x + b$$

其中， w 为权重向量， b 为偏差项， x 为输入特征向量， y 为预测输出。

2. 损失函数：均方误差

- 定义：给定数据集 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ，损失函数为：

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$$

其中， $h_w(x_i) = w^T x_i + b$ 为模型对第 i 个样本的预测值。

- 选择原因：均方误差是凸函数，存在唯一最小值，且数学性质良好，便于通过梯度下降法求解；同时能有效衡量预测值与真实值的平均偏差程度。

3. 参数更新：梯度下降法

- 权重 w 的梯度计算：

$$\frac{\partial L}{\partial w} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)x_i$$

- 偏差 b 的梯度计算：

$$\frac{\partial L}{\partial b} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)$$

- 更新公式：

$$w = w - \alpha \cdot \frac{\partial L}{\partial w}$$
$$b = b - \alpha \cdot \frac{\partial L}{\partial b}$$

其中， α 为学习率，控制每次参数更新的步长。

4. ℓ_2 正则化（岭回归）

- 正则化目的：防止模型过拟合，通过惩罚过大的权重值，使模型更简洁。
- 正则化后损失函数：

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2 + \lambda \sum_{j=1}^d w_j^2$$

其中， λ 为正则化参数，控制惩罚力度； d 为权重向量的维度。

- 正则化后权重更新公式：

$$\frac{\partial L}{\partial w} = \frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)x_i + 2\lambda w$$
$$w = w - \alpha \cdot \left(\frac{2}{n} \sum_{i=1}^n (h_w(x_i) - y_i)x_i + 2\lambda w \right)$$

偏差 b 的更新公式与无正则化时一致。

二、感知器

1. 数学模型与激活函数

感知器是最简单的线性分类模型，其数学模型为：

$$y = \begin{cases} 1 & w^T x + b > 0 \\ 0 & w^T x + b \leq 0 \end{cases}$$

其中，激活函数为分段函数，将线性组合 $w^T x + b$ 的结果映射为二分类标签（0 或 1）。

2. 学习规则与权重更新

- 损失函数：感知器的损失函数定义为误分类样本到决策超平面的距离之和：

$$L(w, b) = - \sum_{x_i \in M} y_i (w^T x_i + b)$$

其中， M 为误分类样本的集合。

- 权重更新规则：当样本被错误分类时，根据梯度下降法更新权重和偏差，具体公式为：

$$w = w + \eta y_i x_i$$

$$b = b + \eta y_i$$

其中， η 为学习率（ $0 < \eta \leq 1$ ），通过迭代修正参数，直至无错误分类样本。

三、逻辑回归

1. 模型数学形式

逻辑回归用于二分类任务，通过 Sigmoid 函数将线性输出映射为概率值，模型形式为：

$$h_w(x) = \frac{1}{1 + \exp(-w^T x)}$$

其中， $h_w(x)$ 表示样本属于正类的概率，取值范围为(0,1)。

2. 损失函数：交叉熵损失

- 定义：基于极大似然估计推导，损失函数为：

$$L(w) = -\frac{1}{n} \sum_{i=1}^n [y_i \log h_w(x_i) + (1 - y_i) \log(1 - h_w(x_i))]$$

其中， y_i 为样本真实标签（0 或 1）。

- 推导逻辑：假设样本服从伯努利分布，通过极大似然估计最大化样本出现的概率，取对数后转化为最小化交叉熵损失。

3. 参数更新：梯度下降法

- 梯度计算：

$$\frac{\partial L}{\partial w} = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i) x_i$$

- 更新公式：

$$w = w - \alpha \cdot \frac{\partial L}{\partial w}$$

4. ℓ_1 正则化 (Lasso 回归)

- 正则化后损失函数:

$$L(w) = -\frac{1}{n} \sum_{i=1}^n [y_i \log h_w(x_i) + (1 - y_i) \log(1 - h_w(x_i))] + \lambda \sum_{j=1}^d |w_j|$$

其中, λ 为正则化参数, ℓ_1 正则化会使部分权重变为 0, 实现特征选择。

四、基础计算题：偏导数与梯度求解

1. 题目 1

已知 $f(w_i) = \frac{\exp(w_i) - \exp(-w_i)}{\exp(w_i) + \exp(-w_i)}$, 求 $\frac{\partial f}{\partial w_i}$ 。

- 解答: 令 $f(w_i) = \tanh(w_i)$ (双曲正切函数), 其导数为:

$$\frac{\partial f}{\partial w_i} = 1 - f(w_i)^2$$

2. 题目 2

已知 $f(x) = \frac{1}{2} x^T x$, 求 $\nabla_x f(x)$ 。

- 解答: 展开得 $f(x) = \frac{1}{2} \sum_{i=1}^d x_i^2$, 梯度为:

$$\nabla_x f(x) = x$$

3. 题目 3

已知 $f(x) = \frac{1}{2} x^T A x + b^T x$, 求 $\nabla_x f(x)$ 。

- 解答: 利用矩阵求导法则, 梯度为:

$$\nabla_x f(x) = \frac{1}{2} (A + A^T) x + b$$

若 A 为对称矩阵 ($A = A^T$), 则简化为 $\nabla_x f(x) = A x + b$ 。

第三部分 进阶模型：神经网络入门

一、神经网络基础

1. 学习动机

感知器仅能解决线性可分问题, 而现实中的许多任务 (如“异或”分类) 属于非线性问题, 神经网络通过多层结构和非线性激活函数, 具备处理非线性问题的能力。

2. 基础结构

神经网络由输入层、隐藏层和输出层组成：

- 输入层：接收原始数据，神经元数量等于输入特征维度。
- 隐藏层：位于输入层和输出层之间，通过非线性变换提取数据的高阶特征，神经元数量可灵活设置。
- 输出层：输出模型预测结果，分类任务常用 Sigmoid（二分类）或 Softmax（多分类）激活函数，回归任务无激活函数。

3. 激活函数的作用

激活函数为神经网络引入非线性，使模型能够拟合复杂的非线性映射。若隐藏层使用线性激活函数，多层网络将等价于单层线性模型，失去深层结构的优势。常用激活函数为 Sigmoid 函数： $\sigma(a) = \frac{1}{1+\exp(-a)}$ ，其导数为 $\sigma'(a) = \sigma(a)(1 - \sigma(a))$ 。

二、前向传播

前向传播是从输入层到输出层的计算过程，通过逐层计算神经元的输入和输出，得到模型的预测结果。

例题

给定三层神经网络：

- 输入层：1 个神经元，输入 $x = [0.5]$ 。
- 隐藏层：2 个神经元，输入到隐藏层权重 $w^{(1)} = [0.15, 0.25]$ ，偏置 $b^{(1)} = [0.2, 0.3]$ 。
- 输出层：1 个神经元，隐藏到输出层权重 $w^{(2)} = [0.4, 0.5]$ ，偏置 $b^{(2)} = [0.6]$ 。
- 激活函数：Sigmoid 函数。

计算过程：

1. 隐藏层神经元输入：

$$z_1^{(1)} = w_1^{(1)}x + b_1^{(1)} = 0.15 \times 0.5 + 0.2 = 0.275$$

$$z_2^{(1)} = w_2^{(1)}x + b_2^{(1)} = 0.25 \times 0.5 + 0.3 = 0.425$$

2. 隐藏层神经元输出：

$$a_1^{(1)} = \sigma(z_1^{(1)}) = \frac{1}{1 + \exp(-0.275)} \approx 0.568$$

$$a_2^{(1)} = \sigma(z_2^{(1)}) = \frac{1}{1 + \exp(-0.425)} \approx 0.605$$

3. 输出层神经元输入：

$$z^{(2)} = w_1^{(2)} a_1^{(1)} + w_2^{(2)} a_2^{(1)} + b^{(2)} = 0.4 \times 0.568 + 0.5 \times 0.605 + 0.6 \approx 1.190$$

4. 输出层神经元输出：

$$\hat{y} = \sigma(z^{(2)}) = \frac{1}{1 + \exp(-1.190)} \approx 0.767$$

三、反向传播

反向传播算法通过链式法则计算损失函数对各层参数的梯度，进而通过梯度下降法更新参数，最小化损失函数。

1. 核心步骤

1. 前向传播：计算各层神经元的输入和输出，得到预测值 $\hat{y}$ 。
2. 计算输出层误差：基于损失函数计算输出层神经元的误差。
3. 反向传播误差：从输出层向隐藏层传播误差，计算各层神经元的误差项。
4. 计算参数梯度：利用误差项和神经元输出计算权重和偏置的梯度。
5. 更新参数：根据梯度和学习率更新模型参数。

2. 链式法则的作用

链式法则是反向传播的核心，用于计算复合函数的导数。在神经网络中，损失函数是各层参数的复合函数，通过链式法则可逐层推导损失函数对每个参数的梯度，避免直接计算的复杂性，提高计算效率。

例题

已知期望输出 $y = 1$ ，学习率 $\alpha = 0.1$ 。

计算过程：

1. 输出层误差（采用均方误差损失）：

$$L = \frac{1}{2}(\hat{y} - y)^2 = \frac{1}{2}(0.767 - 1)^2 \approx 0.0279$$

输出层误差项：

$$\delta^{(2)} = (\hat{y} - y) \cdot \sigma'(z^{(2)}) = (0.767 - 1) \times 0.767 \times (1 - 0.767) \approx -0.0415$$

2. 隐藏层到输出层权重梯度：

$$\frac{\partial L}{\partial w_1^{(2)}} = \delta^{(2)} \cdot a_1^{(1)} \approx -0.0415 \times 0.568 \approx -0.0236$$

$$\frac{\partial L}{\partial w_2^{(2)}} = \delta^{(2)} \cdot a_2^{(1)} \approx -0.0415 \times 0.605 \approx -0.0251$$

3. 权重更新:

$$w_1^{(2)} = w_1^{(2)} - \alpha \cdot \frac{\partial L}{\partial w_1^{(2)}} = 0.4 - 0.1 \times (-0.0236) \approx 0.4024$$

$$w_2^{(2)} = w_2^{(2)} - \alpha \cdot \frac{\partial L}{\partial w_2^{(2)}} = 0.5 - 0.1 \times (-0.0251) \approx 0.5025$$

四、神经网络分析

1. 模型参数维度

给定输入变量 D 维、隐藏变量 M 维、输出变量 K 维，且各层包含偏置项:

- 输入层到隐藏层权重 $w^{(1)}$: 维度为 $M \times (D + 1)$ (M 个隐藏神经元，每个神经元对应 D 个输入特征权重+1 个偏置权重)。
- 隐藏层到输出层权重 $w^{(2)}$: 维度为 $K \times (M + 1)$ (K 个输出神经元，每个神经元对应 M 个隐藏特征权重+1 个偏置权重)。

2. 矢量形式前向传递函数

$$a^{(1)} = \sigma(w^{(1)}x + b^{(1)})$$

$$y = \sigma(w^{(2)}a^{(1)} + b^{(2)})$$

其中， $a^{(1)}$ 为隐藏层输出向量， x 为输入向量， y 为输出向量， σ 为 Sigmoid 激活函数 (逐元素计算)。

3. 第一层参数导数 $\frac{\partial y_k}{\partial w_{md}}$

$$\left[\frac{\partial y_k}{\partial w_{md}} = y_k(1 - y_k) \cdot w_{km}^{(2)} \cdot a_m^{(1)}(1 - a_m^{(1)}) \cdot x_d \right]$$

其中， y_k 为第 k 个输出神经元的输出， $w_{km}^{(2)}$ 为隐藏层第 m 个神经元到输出层第 k 个神经元的权重， $a_m^{(1)}$ 为第 m 个隐藏神经元的输出， x_d 为第 d 个输入特征。

五、练习：构造“异或”神经网络

1. 异或问题描述

输入 x_1	输入 x_2	输出 y
0	0	0
0	1	1
1	0	1
1	1	0

2. 网络结构设计

- 输入层：2 个神经元（对应 x_1 、 x_2 ）。
- 隐藏层：2 个神经元（引入非线性）。
- 输出层：1 个神经元（输出分类结果）。
- 激活函数：Sigmoid 函数。

3. 参数设置（示例）

- 输入到隐藏层权重： $w^{(1)} = \begin{bmatrix} 10 & 10 \\ 10 & 10 \end{bmatrix}$ ，偏置 $b^{(1)} = \begin{bmatrix} -5 \\ -15 \end{bmatrix}$ 。
- 隐藏到输出层权重： $w^{(2)} = \begin{bmatrix} 10 \\ -10 \end{bmatrix}$ ，偏置 $b^{(2)} = [-5]$ 。

4. 验证过程

通过前向传播计算各输入组合的输出，验证是否符合异或逻辑（略）。

第四部分 模型优化与评价

一、数据降维与特征选择

1. 数据降维的目的

- 数据可视化：将高维数据降至 2 维或 3 维，便于观察数据分布。
- 提高模型效率：减少特征维度，降低计算复杂度，加快算法收敛。
- 缓解维数灾难：高维数据样本稀疏，降维后可避免模型过拟合。
- 减少冗余信息：去除无关或冗余特征，提高模型预测精度。

2. PCA 与 LDA 的区别

对比维度	PCA（主成分分析）	LDA（线性鉴别分析）
监督属性	无监督学习	有监督学习
降维限制	无明确维度限制，可降至任意小于原维度	最多降至类别数 K-1 维
核心目标	选择数据投影后方差最大的方向，保留数据主要信息	选择类内离散度最小、类间离散度最大的方向，优化分类性能
主要应用	数据降维、去噪	数据降维、分类

3. 主成分分析（PCA）

（1）目标函数与求解方法（最大方差视角）

- 目标：将数据投影到单位向量 u_1 上，使投影后的数据方差最大。
- 均值计算： $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 。
- 协方差矩阵： $S = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$ 。
- 目标函数： $J(u_1) = u_1^T S u_1$ ，约束条件 $u_1^T u_1 = 1$ 。
- 求解：引入拉格朗日乘数 λ ，构造 $L = u_1^T S u_1 + \lambda(1 - u_1^T u_1)$ ，求导得 $S u_1 = \lambda u_1$ ， u_1 为协方差矩阵 S 的最大特征值对应的特征向量。

（2）目标函数与求解方法（最小重构误差视角）

- 目标：通过前 M 个主成分重构数据，使重构误差最小。
- 重构误差： $J = \frac{1}{n} \sum_{i=1}^n |x_i - \hat{x}_i|^2$ ，其中 $\hat{x}_i$ 为重构数据。
- 求解：重构误差最小等价于保留协方差矩阵的前 M 个最大特征值对应的特征向量，舍弃较小特征值对应的特征向量。

（3）实例计算

已知样本 $x_1 = (2, 1)^T$ 、 $x_2 = (2, 4)^T$ 、 $x_3 = (5, 4)^T$ ，求主成分并降维。

- 计算均值： $\bar{x} = \left(\frac{2+2+5}{3}, \frac{1+4+4}{3} \right)^T = (3, 3)^T$ 。
- 去中心化： $x_1 - \bar{x} = (-1, -2)^T$ ， $x_2 - \bar{x} = (-1, 1)^T$ ， $x_3 - \bar{x} = (2, 1)^T$ 。
- 协方差矩阵： $S =$

$$\frac{1}{3} \begin{bmatrix} (-1)(-1) + (-1)(-1) + 2 \times 2 & (-1)(-2) + (-1) \times 1 + 2 \times 1 \\ (-2)(-1) + 1 \times (-1) + 1 \times 2 & (-2)(-2) + 1 \times 1 + 1 \times 1 \end{bmatrix} = \frac{1}{3} \begin{bmatrix} 6 & 3 \\ 3 & 6 \end{bmatrix}。$$

4. 特征值与特征向量：求解 $|S - \lambda I| = 0$ ，得 $\lambda_1 = 3$ ， $\lambda_2 = 1$ ；对应的特征向量 $u_1 = \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}\right)^T$ ， $u_2 = \left(\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2}\right)^T$ 。

5. 降维：选择最大特征值对应的特征向量 u_1 作为主成分，将数据投影到 u_1 上，得到降维后的一维数据。

4. 线性鉴别分析 (LDA)

(1) 目标函数

- 类内离散度矩阵： $S_w = \sum_{c=1}^C S_c$ ，其中 $S_c = \sum_{x_i \in C_c} (x_i - \mu_c)(x_i - \mu_c)^T$ ， μ_c 为第 c 类样本均值。
- 类间离散度矩阵： $S_b = \sum_{c=1}^C n_c(\mu_c - \mu)(\mu_c - \mu)^T$ ，其中 μ 为全局样本均值， n_c 为第 c 类样本数量。
- 目标函数： $J(w) = \frac{w^T S_b w}{w^T S_w w}$ ，即最大化类间离散度与类内离散度的比值。

(2) 优化求解方法

- 构造拉格朗日函数： $L(w, \lambda) = w^T S_b w - \lambda(w^T S_w w - 1)$ 。
- 求导得： $S_b w = \lambda S_w w$ ，即 $S_w^{-1} S_b w = \lambda w$ 。
- 求解： w 为 $S_w^{-1} S_b$ 的最大特征值对应的特征向量。

5. 特征选择算法

(1) 滤波式选择

- 原理：先对特征进行筛选（基于特征与标签的相关性等统计指标），再训练学习器，特征选择过程与学习器无关。
- 特点：计算速度快，通用性强，但未考虑特征与学习器的适配性。
- 示例：基于皮尔逊相关系数、互信息筛选特征。

(2) 封装式选择

- 原理：将学习器的性能作为特征子集的评价标准，为特定学习器“量身定制”最优特征子集。
- 特点：选择的特征子集适配性好，预测精度高，但计算复杂度高，耗时长。
- 示例：递归特征消除（RFE）。

(3) 嵌入式选择

- 原理：将特征选择与学习器训练过程融为一体，在训练中自动筛选重要特征。
- 特点：兼顾计算效率与适配性，是常用的特征选择方式。
- 示例：Lasso 回归 (ℓ_1 正则化)、决策树模型。

6. 流形学习与 LLE 原理

(1) 流形学习定义

流形学习是一类借鉴微分几何中“流形”概念的降维方法。流形是局部与欧氏空间同胚的空间，高维数据通常分布在低维流形上，流形学习通过挖掘数据的局部结构，实现高维到低维的映射。

(2) LLE（局部线性嵌入）原理

- 邻域选择：为每个样本 x_i 选择 k 个最近邻样本。
- 局部重构：用邻域样本线性重构 x_i ，计算重构权重 w_{ij} （满足 $\sum_j w_{ij} = 1$ ）。
- 低维映射：在低维空间中保持重构权重 w_{ij} 不变，求解样本的低维坐标。

二、模型评价方法

1. ROC 曲线绘制（两类分类问题）

(1) 核心指标

- 真正例率 (TPR): $TPR = \frac{TP}{TP+FN}$ ，反映模型识别正例的能力。
- 假正例率 (FPR): $FPR = \frac{FP}{FP+TN}$ ，反映模型将负例误判为正例的概率。

其中，TP（真正例）、TN（真负例）、FP（假正例）、FN（假负例）构成分类混淆矩阵。

(2) 绘制步骤

- 收集所有样本的预测概率和真实标签。
- 按预测概率从高到低对样本排序。
- 依次将每个样本的预测概率作为分类阈值，计算对应的 TPR 和 FPR。
- 以 FPR 为横轴、TPR 为纵轴，连接所有 (FPR, TPR) 点，得到 ROC 曲线。

2. F_1 曲线绘制

(1) 核心指标

- 精确率 (P): $P = \frac{TP}{TP+FP}$, 反映模型预测正例的准确性。
- 召回率 (R): $R = \frac{TP}{TP+FN}$, 反映模型覆盖正例的完整性。
- F_1 分数: $F_1 = \frac{2PR}{P+R}$, 是精确率与召回率的调和平均, 综合衡量模型性能。

(2) 绘制步骤

1. 按预测概率从高到低对样本排序。
2. 依次将每个样本的预测概率作为分类阈值, 计算对应的 P 和 R, 进而得到 F_1 分数。
3. 以阈值为横轴、 F_1 分数为纵轴, 连接所有点, 得到 F_1 曲线。

3. K 折交叉验证

- 定义: 将数据集 D 划分为 K 个互不相交的子集 $D_1, D_2, \dots, D_K$ (规模相近), 每次用 K-1 个子集的并集作为训练集, 剩余 1 个子集作为测试集, 重复 K 次, 取 K 次测试结果的平均值作为模型性能评估指标。
- K 的最大取值: 样本个数 (此时为留一法)。
- 优点: 充分利用数据, 评估结果稳定可靠, 避免过拟合。

4. 留一法

- 定义: 当 K 等于样本个数 n 时, 每次仅用 1 个样本作为测试集, 其余 n-1 个样本作为训练集, 共进行 n 次实验, 取 n 次测试结果的平均值作为评估指标。
- 优点: 评估结果准确, 无随机划分误差; 缺点: 计算复杂度高 (n 次训练), 适用于小样本数据集。

5. 偏差-方差分解

(1) 核心定义

- 期望预测: $\bar{f}(x) = E_D[f(x; D)]$, 其中 $f(x; D)$ 为基于训练集 D 的模型预测值。
- 偏差: $bias^2(x) = (\bar{f}(x) - y)^2$, 衡量期望预测与真实标签的偏离程度 (模型拟合能力)。
- 方差: $var(x) = E_D \left[(f(x; D) - \bar{f}(x))^2 \right]$, 衡量不同训练集导致的预测波动 (模型稳定性)。
- 噪声: $\epsilon^2 = E_D[(y_D - y)^2]$, 衡量数据本身的不确定性 (不可避免)。

(2) 分解公式

$$E(f; D) = bias^2(x) + var(x) + \epsilon^2$$

即模型的期望泛化误差等于偏差平方、方差与噪声之和。

(3) 模型改进策略

情况	特征	改进策略
高偏差（欠拟合）	模型过于简单，无法拟合数据规律，训练误差和测试误差均较高	1. 增加模型复杂度（如增加神经网络隐藏层神经元数量、提高多项式回归次数）；2. 增加特征数量（补充有效特征）；3. 减小正则化强度
高方差（过拟合）	模型过于复杂，拟合数据噪声，训练误差低但测试误差高	1. 增加训练数据量；2. 减少特征数量（特征选择、降维）；3. 增大正则化强度；4. 简化模型结构（如减少神经网络层数）

第五部分 高级模型：概率图模型

一、概率图模型基础

1. 定义

概率图模型是一类用图来表达变量间概率相关关系的概率模型。图中节点表示随机变量（或变量组），边表示变量间的依赖关系（或关联关系），通过图结构直观呈现变量间的概率关系，简化概率计算和推理过程。

二、贝叶斯网络

1. 结构特点

- 图结构：有向无环图（DAG），有向边表示变量间的直接因果关系。
- 条件独立性：给定父节点，节点与其他非后代节点条件独立（局部马尔可夫性）。

2. 联合概率计算

- 链式法则：对于变量 $x_1, x_2, \dots, x_K$ ，联合概率分布为各节点条件概率的乘积：

$$p(x) = \prod_{k=1}^K p(x_k | pa_k)$$

其中， pa_k 为节点 x_k 的父节点集合。

- 示例：若贝叶斯网络结构为 $x_1 \rightarrow x_2 \rightarrow x_3$ ，则联合概率为 $p(x_1, x_2, x_3) = p(x_1)p(x_2|x_1)p(x_3|x_2)$ 。

三、马尔可夫随机场

1. 结构特点

- 图结构：无向图，边表示变量间的关联性（无明确因果关系）。
- 条件独立性：给定节点的邻居节点，节点与其他非邻居节点条件独立（局部马尔可夫性）。

2. 核心概念：团与极大团

- 团：图中任意两个节点间都有边相连的子集。
- 极大团：无法通过添加其他节点扩展为更大团的团（即不被任何其他团包含）。
- 示例：在无向图中，若节点 x_2 与 x_5 、 x_6 均相连，且 x_5 与 x_6 相连，则 x_2, x_5, x_6 为极大团。

3. 联合概率分布

- 基于团的分解：联合概率分布可表示为所有极大团上势函数的乘积与规范化因子之比：

$$p(x) = \frac{1}{Z^*} \prod_{Q \in C^*} \psi_Q(x_Q)$$

其中， C^* 为极大团集合， $\psi_Q(x_Q)$ 为团 Q 对应的势函数（非负函数，衡量团内变量取值的相容性）， $Z^* = \sum_x \prod_{Q \in C^*} \psi_Q(x_Q)$ 为规范化因子，确保概率和为 1。

- 势函数形式：常用指数函数定义： $\psi_Q(x_Q) = e^{-H_Q(x_Q)}$ ，其中 $H_Q(x_Q) = \sum_{u,v \in Q, u \neq v} \alpha_{uv} x_u x_v + \sum_{v \in Q} \beta_v x_v$ ， α_{uv} 和 β_v 为参数。

四、贝叶斯网络与马尔可夫随机场的区别

对比维度	贝叶斯网络	马尔可夫随机场
------	-------	---------

图结构	有向无环图 (DAG)	无向图
依赖关系	有向边表示直接因果关系	无向边表示关联性 (无因果)
条件独立性	给定父节点, 与非后代节点独立	给定邻居节点, 与非邻居节点独立
概率分解	各节点条件概率的乘积	极大团势函数的乘积/规范化因子
应用场景	推断、诊断、因果关系建模	图像分割、能量最小化、模式识别

五、条件独立性的作用

- 模型简化: 减少需建模和存储的参数数量, 降低模型复杂度。
- 高效推断: 已知部分变量时, 利用条件独立性可快速计算未知变量的后验分布。
- 模型解释: 通过图结构直观呈现变量间的依赖关系, 便于理解模型逻辑。
- 特征选择: 帮助识别对预测重要的特征, 剔除无关特征。

六、概率图模型联合概率实例

1. 图 1(a) (贝叶斯网络)

联合概率分布:

$$p(x) = p(x_1)p(x_2)p(x_3)p(x_4|x_1'x_2'x_3)p(x_5|x_1'x_3)p(x_6|x_4)p(x_7|x_4'x_5)$$

2. 图 1(b) (马尔可夫随机场)

联合概率分布:

$$p(X) = \frac{1}{Z} \phi_{\{BC\}}(x_B, x_C) \phi_{\{ABED\}}(x_A, x_B, x_E, x_D)$$

其中, $Z = \sum_X (\phi_{\{BC\}}(x_B, x_C) \phi_{\{ABED\}}(x_A, x_B, x_E, x_D))$ 为规范化因子。

附录：常用公式汇总

1. 线性模型相关

- 线性回归模型: $y = w^T x + b$
- 逻辑回归模型: $h_w(x) = \frac{1}{1 + \exp(-w^T x)}$
- 均方误差损失: $L = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$
- 交叉熵损失: $L = -\frac{1}{n} \sum_{i=1}^n [y_i \log h_w(x_i) + (1 - y_i) \log(1 - h_w(x_i))]$

2. 神经网络相关

- Sigmoid 函数: $\sigma(a) = \frac{1}{1 + \exp(-a)}$
- Sigmoid 导数: $\sigma'(a) = \sigma(a)(1 - \sigma(a))$
- 前向传播 (隐藏层): $a^{(1)} = \sigma(w^{(1)}x + b^{(1)})$
- 前向传播 (输出层): $y = \sigma(w^{(2)}a^{(1)} + b^{(2)})$

3. 降维相关

- PCA 协方差矩阵: $S = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$
- LDA 目标函数: $J(w) = \frac{w^T S_b w}{w^T S_w w}$

4. 模型评价相关

- TPR: $TPR = \frac{TP}{TP + FN}$
- FPR: $FPR = \frac{FP}{FP + TN}$
- F_1 分数: $F_1 = \frac{2PR}{P + R}$
- 偏差-方差分解: $E(f; D) = \text{bias}^2(x) + \text{var}(x) + \epsilon^2$

5. 概率图模型相关

- 贝叶斯网络联合概率: $p(x) = \prod_{k=1}^K p(x_k | pa_k)$
- 马尔可夫随机场联合概率: $p(x) = 1/Z \cdot \prod_{(Q \in \mathcal{C}^*)} \psi_Q(x_Q)$